



(21) 申请号 202410350713.4

(22) 申请日 2024.03.26

(65) 同一申请的已公布的文献号

申请公布号 CN 118332684 A

(43) 申请公布日 2024.07.12

(73) 专利权人 四川大学

地址 610000 四川省成都市一环路南一段
24号

专利权人 中国核动力研究设计院

(72) 发明人 彭德中 刘东 于洋 罗凯升

庞志鑫 孙元 秦阳

(74) 专利代理机构 北京卓岚智财知识产权代理
有限公司 11624

专利代理师 曾勇

(51) Int. Cl.

G06F 30/15 (2020.01)

G06F 30/27 (2020.01)

G06F 18/10 (2023.01)

G06F 18/213 (2023.01)

G06F 18/214 (2023.01)

G06N 3/0464 (2023.01)

G06N 3/048 (2023.01)

G06F 113/08 (2020.01)

G06F 119/14 (2020.01)

(56) 对比文件

CN 115859781 A, 2023.03.28

CN 116227364 A, 2023.06.06

审查员 田梅靖


权利要求书2页 说明书6页 附图1页

(54) 发明名称

一种基于密集卷积网络的流场预测方法

(57) 摘要

本发明公开了一种基于密集卷积网络的流场预测方法,包括以下步骤:获取翼型形状数据集和仿真流场数据集;利用加入自适应Dropout模块的密集卷积网络获取翼型几何参数;构建翼型参数和物理参数输入用例;训练基于MHP的流场预测模型;利用训练好的流场预测模型在不同的翼型数据上预测流场。本发明在使用密集卷积网络提取翼型特征数据时加入了SeLU激活函数和自适应Dropout,缓解了因数据量少而导致的流场预测方法存在的过拟合情况,增强了神经网络的预测精度和泛化性;同时利用多头感知机训练预测模型并进行预测,避免了稀疏数据对其他待预测的气动参数的干扰,弥补了MLP在处理稀疏数据时存在的缺陷,提高的预测的精度。



1.一种基于密集卷积网络的流场预测方法,其特征在于:包括以下步骤:

S1、获取翼型形状数据集及仿真流场数据集,并对翼型形状数据进行预处理;

S2、利用加入自适应Dropout模块的密集卷积网络获取翼型几何参数;

S3、构建翼型参数和物理参数输入用例;

S4、训练基于MHP的流场预测模型;

S5、利用训练好的流场预测模型在不同的翼型数据上预测流场;

所述步骤S1的具体步骤如下:

S11、从翼型形状数据集中获取基准翼型并对其进行拟合,在拟合曲线上得到坐标细节;

S12、获取的坐标生成翼型的倒灰度图像,并在翼型轮廓完全通过的像素设置为1,在翼型轮廓没有通过的像素设置为0,其余像素值设置在0到1之间;

所述步骤S2的具体步骤如下:

S21、对于生成的翼型倒灰度图像 $X \in \mathbb{R}^{C \times H \times W}$,将其输入卷积层进行图像降维,其中,R表示实数域,C表示输入图像的通道数,H和W表示特征图的高度和宽度;输出图像 $F \in \mathbb{R}^{C^{out} \times H^{out} \times W^{out}}$,其中 C^{out} 表示输出通道数, H^{out} 和 W^{out} 表示输出特征图的高度和宽度;

S22、卷积层的输出表示为F依次交替经过密集卷积网络的三个DenseBlock和两个Transition Layer后进行池化和线性操作,得到翼型几何参数;

所述步骤S4的具体步骤如下:

S41、将步骤S2中得到的翼型特征参数和步骤S3中构建的物理特征作为输入,对模型进行训练,利用多头网络得到模型对不同分布特征的物性参数(u,p,v)的预测输出,其具体表达式如下:

$$\begin{cases} f_{MHP-U}(I, Re, AOA, x, y) = u \\ f_{MHP-P}(I, Re, AOA, x, y) = p \\ f_{MHP-V}(I, Re, AOA, x, y) = v \end{cases}$$

其中,公式左侧表示MHP的预测模型,u,p,v分别表示流场的x方向速度分量,压力值和y方向速度分量;

S42、多头感知机中每头的LOSS函数表达式如下:

$$\begin{cases} MHP(u)_{loss} = \frac{1}{N} \sum_{i=1}^N (u_i^t - u_i^p)^2 \\ MHP(p)_{loss} = \frac{1}{N} \sum_{i=1}^N (p_i^t - p_i^p)^2 \\ MHP(v)_{loss} = \frac{1}{N} \sum_{i=1}^N (v_i^t - v_i^p)^2 \end{cases}$$

其中, u_i^t 、 p_i^t 、 v_i^t 分别表示由CFD模拟的流场x方向速度分量,压力值和y方向速度分量, u_i^p 、 p_i^p 、 v_i^p 分别表示预测值;

S43、当LOSS收敛时,训练结束,得到预测模型。

2.根据权利要求1所述的一种基于密集卷积网络的流场预测方法,其特征在于:

所述步骤S3的具体方法如下:

将由密集卷积网络得到的特征参数P,结合翼型控制点坐标(x,y)以及雷诺数(Re)和攻角(AOA)结合组成输入用例,与CFD模拟仿真的流场数据构建训练流场预测模型的数据集。

3.根据权利要求1所述的一种基于密集卷积网络的流场预测方法,其特征在于:

所述步骤S22的具体步骤如下:

S221、卷积层的输出F进入DenseBlock中第一层Denselayer;

S222、Denselayer中的Batch Normalization Layer对其进行批归一化处理,得到归一化后的特征图 Y^{bn} ;

S223、通过激活函数SeLU对特征图 Y^{bn} 进行逐元素操作修正,得到修正后的特征图 Y^{SeLU} , SeLU函数计算公式如下:

$$SeLU(x) = \begin{cases} \lambda x & x > 0 \\ \lambda \alpha e^x - \alpha x & x \leq 0 \end{cases}$$

S224、对修正后的特征图 Y^{SeLU} 进行 1×1 的卷积操作,得到卷积后的特征图 Y^{conv} ;

S225、特征图 Y^{conv} 再次经过Batch Normalization Layer和激活函数SeLU得到 $Y^{SeLU'}$,并对其进行 3×3 的卷积操作,得到特征图 $Y^{conv'}$;

S226、对于卷积后得到的特征图 $Y^{conv'}$ 进行自适应Drop,对其进行最大最小归一化得到 $Y^{(n)}$;使用伯努利分布Bernoulli(γ)进行随机采样,得到若干像素点 $M_{i,j}$,对于每个像素点 $M_{i,j}$,以其为中心设置一个大小为 $block_size \times block_size$ 的像素块,在每个像素块中,前k个百分位的元素设置为0,其余元素设置为1,进而生成一个模板M, $Y^{(n)}$ 的表达式如下:

$$Y^{(n)} = Y^{conv'} \times M$$

再对 $Y^{(n)}$ 进行缩放输出,其表达式如下:

$$Y^{(n+1)} = Y^{(n)} \times count(M) \div count_ones(M)$$

其中, $count(M)$ 表示模板M中元素的个数, $count_ones(M)$ 表示模板M中1的个数, γ 表示控制需要Drop的特征数量,其表达式如下:

$$\gamma = \frac{1 - keep_prob}{block_size^2} \cdot \frac{feat_size^2}{(feat_size - block_size + 1)^2}$$

其中, $keep_prob$ 表示将单元块保留的概率; $feat_size$ 表示特征图大小;

S227、第一层Denselayer的输出 $Y^{(n+1)}$ 依次输入到后续三层Denselayer中,且每一层Denselayer的输入均由前面所有Denselayer层输出的特征结合得到,其表达式如下:

$$x_t = H_t([x_0, x_1, x_2 \cdots x_{t-1}])$$

其中, $x_0, x_1, x_2 \cdots x_{t-1}$ 表示指在层 $0, 1, \cdots, t-1$ 中产生特征图的串联, $H_t(\cdot)$ 函数表示t层Denselayer提取特征的过程;

S228、第四层Denselayer的输出,第一个DenseBlock得到的特征图输入到Transition Layer,通过 1×1 的卷积核进行特征通道降维,再通过 2×2 平均池化层进行特征下采样;并继续输入到接下来的DenseBlock、Transition Layer及DenseBlock;

S229、从最后一个Denseblock模块输出的特征图Y,经过池化层和线性层得到翼型特征参数P。

一种基于密集卷积网络的流场预测方法

技术领域

[0001] 本发明属于流场预测技术领域,具体涉及一种基于密集卷积网络的流场预测方法。

背景技术

[0002] 翼型是在航空航天以及能源动力等领域广泛应用的一个重要的流体力学软件。翼型的流场预测是指使用数值模拟技术来预测和分析翼型在不同风洞或气流条件下的流动行为,是评估飞行器设计和翼型性能的其中一个重要过程。翼型流场预测在航空航天、飞机设计、风力发电、汽车工程等领域都具有重要应用,它能够提供有关翼型性能的关键信息,以指导产品设计和性能改进。最初获取翼型流场数据的方法是通过风洞试验获得结果,但该方法所需要的时间和经济成本较大,常用于飞行器设计后期阶段。后来兴起的计算流体力学(CFD)方法可用于获取翼型的流场,该方法需要利用解算软件迭代计算进行高精度的数值仿真模拟,例如求解欧拉方程、雷诺平均纳维尔-斯托克斯(RANS)方程等,然而此方法也要花费很长的时间,且对硬件有着较高的要求。

[0003] 随着深度学习的发展,利用神经网络来构建回归预测模型自动学习高维潜在映射关系,实现流场的快速预测,能够在一定程度上逼近解算软件数值模拟结果,从而为研究人员提供便捷。然而,现有的深度学习神经网络无法有效提取翼型的复杂特征,使得流场预测的准确性不高,同时,要训练神经网络预测模型需要大量的数据,对数据的高要求成为这些模型实用化的主要障碍,当数据不足时,模型通常会存在过拟合等性能问题。因此,如何设计一种能够有效提取翼型特征,在小规模数据集上提高翼型流场预测的准确性和泛化性的流场预测方法是亟待解决的问题。

发明内容

[0004] 本发明要解决的技术问题在于一种基于密集卷积网络的流场预测方法,该预测方法提高流场预测领域在小规模数据集上训练的泛化性和准确性,缓解了流场预测领域因数据量少而过拟合的问题。

[0005] 为了解决上述技术问题,本发明通过以下方式来实现:

[0006] 一种基于密集卷积网络的流场预测方法,包括以下步骤:

[0007] S1、获取翼型形状数据集及仿真流场数据集,并对翼型形状数据进行预处理;

[0008] S2、利用加入自适应Dropout模块的密集卷积网络获取翼型几何参数;

[0009] S3、构建翼型参数和物理参数输入用例;

[0010] S4、训练基于MHP的流场预测模型;

[0011] S5、利用训练好的流场预测模型在不同的翼型数据上预测流场。

[0012] 进一步地,所述步骤S1的具体步骤如下:

[0013] S11、从翼型形状数据集中获取基准翼型并对其进行拟合,在拟合曲线上得到坐标细节;

[0014] S12、获取的坐标生成翼型的倒灰度图像,并在翼型轮廓完全通过的像素设置为1,在翼型轮廓没有通过的像素设置为0,其余像素值设置在0到1之间。

[0015] 进一步地,所述步骤S2的具体步骤如下:

[0016] S21、对于生成的翼型倒灰度图像 $X \in \mathbb{R}^{C \times H \times W}$,将其输入卷积层进行图像降维,其中, $\mathbb{R}$ 表示实数域, C 表示输入图像的通道数, H 和 W 表示特征图的高度和宽度;输出图像 $F \in \mathbb{R}^{C^{out} \times H^{out} \times W^{out}}$,其中 C^{out} 表示输出通道数, H^{out} 和 W^{out} 表示输出特征图的高度和宽度;

[0017] S22、卷积层的输出表示为 F 依次交替经过密集卷积网络的三个DenseBlock和两个Transition Layer后进行池化和线性操作,得到翼型几何参数。

[0018] 进一步的,所述步骤S22的具体步骤如下:

[0019] S221、卷积层的输出 F 进入DenseBlock中第一层Denselayer;

[0020] S222、Denselayer中的Batch Normalization Layer对其进行批归一化处理,得到归一化后的特征图 Y^{bn} ;

[0021] S223、通过激活函数SeLU对特征图 Y^{bn} 进行逐元素操作修正,得到修正后的特征图 Y^{SeLU} ,SeLU函数计算公式如下:

$$[0022] \quad SeLU(x) = \begin{cases} \lambda x & x > 0 \\ \lambda \alpha e^x - \alpha x & x \leq 0 \end{cases}$$

[0023] S224、对修正后的特征图 Y^{SeLU} 进行 1×1 的卷积操作,得到卷积后的特征图 Y^{conv} ;

[0024] S225、特征图 Y^{conv} 再次经过Batch Normalization Layer和激活函数SeLU得到 $Y^{SeLU'}$,并对其进行 3×3 的卷积操作,得到特征图 $Y^{conv'}$;

[0025] S226、对于卷积后得到的特征图 $Y^{conv'}$ 进行自适应Drop,对其进行最大最小归一化得到 $Y^{(n)}$;使用伯努利分布Bernoulli(γ)进行随机采样,得到若干像素点 $M_{i,j}$,对于每个像素点 $M_{i,j}$,以其为中心设置一个大小为block_size $\times$ block_size的像素块,在每个像素块中,前 k 个百分位的元素设置为0,其余元素设置为1,进而生成一个模板 M , $Y^{(n)}$ 的表达式如下:

$$[0026] \quad Y^{(n)} = Y^{(n)} \times M$$

[0027] 再对 $Y^{(n)}$ 进行缩放输出,其表达式如下:

$$[0028] \quad Y^{(n+1)} = Y^{(n)} \times \text{count}(M) \div \text{count_ones}(M)$$

[0029] 其中,count(M)表示模板 M 中元素的个数,count_ones(M)表示模板 M 中1的个数, γ 表示控制需要Drop的特征数量,其表达式如下:

$$[0030] \quad \gamma = \frac{1 - \text{keep_prob}}{\text{block_size}^2} \cdot \frac{\text{feat_size}^2}{(\text{feat_size} - \text{block_size} + 1)^2}$$

[0031] 其中,keep_prob表示将单元块保留的概率;feat_size表示特征图大小;

[0032] S227、第一层Denselayer的输出 $Y^{(n+1)}$ 依次输入到后续三层Denselayer中,且每一层Denselayer的输入均由前面所有Denselayer层输出的特征结合得到,其表达式如下:

$$[0033] \quad x_i = H_i([x_0, x_1, x_2 \dots x_{i-1}])$$

[0034] 其中, $x_0, x_1, x_2 \dots x_{i-1}$ 表示指在层0,1,...,i-1中产生特征图的串联, $H_i(\cdot)$ 函数表示 i 层Denselayer提取特征的过程;

[0035] S228、第四层Denselayer的输出,即第一个DenseBlock得到的特征图输入到Transition Layer,通过 1×1 的卷积核进行特征通道降维,再通过 2×2 平均池化层进行特

征下采样;并继续输入到接下来的DenseBlock、Transition Layer及DenseBlock;

[0036] S229、从最后一个Denseblock模块输出的特征图Y,经过池化层和线性层得到翼型特征参数P。

[0037] 进一步地,所述步骤S3的具体方法如下:

[0038] 将由密集卷积网络得到的特征参数P,结合翼型控制点坐标(x,y)以及雷诺数(Re)和攻角(AOA)结合组成输入用例,与CFD模拟仿真的流场数据构建训练流场预测模型的数据集。

[0039] 进一步地,所述步骤S4的具体步骤如下:

[0040] S41、将步骤S2中得到的翼型特征参数和步骤S3中构建的物理特征作为输入,对模型进行训练,利用多头网络得到模型对不同分布特征的物性参数(u,p,v)的预测输出,其具体表达式如下:

$$[0041] \quad \begin{cases} f_{MHP-U}(I, Re, AOA, x, y) = u \\ f_{MHP-P}(I, Re, AOA, x, y) = p \\ f_{MHP-V}(I, Re, AOA, x, y) = v \end{cases}$$

[0042] 其中,公式左侧表示MHP的预测模型,u,p,v分别表示流场的x方向速度分量,压力值和y方向速度分量;

[0043] S42、多头感知机中每头的LOSS函数表达式如下:

$$[0044] \quad \begin{cases} MHP(u)_{loss} = \frac{1}{N} \sum_{i=1}^N (u_i^t - u_i^p)^2 \\ MHP(p)_{loss} = \frac{1}{N} \sum_{i=1}^N (p_i^t - p_i^p)^2 \\ MHP(v)_{loss} = \frac{1}{N} \sum_{i=1}^N (v_i^t - v_i^p)^2 \end{cases}$$

[0045] 其中, u_i^t 、 p_i^t 、 v_i^t 分别表示由CFD模拟的流场x方向速度分量,压力值和y方向速度分量, u_i^p 、 p_i^p 、 v_i^p 分别表示预测值;

[0046] S43、当LOSS收敛时,训练结束,得到预测模型。

[0047] 与现有技术相比,本发明具有的有益效果:

[0048] 本发明通过加入自适应Dropout模块的密集卷积网络提取翼型特征,缓解了因数据量少而导致的流场预测方法存在的过拟合情况,有助于提高网络的正则化能力,增强了神经网络的预测精度和泛化性;同时利用多头感知机训练预测模型并进行预测,避免了稀疏数据对其他待预测的气动参数的干扰,弥补了MLP在处理稀疏数据时存在的缺陷,提高的预测的精度。通过设置Drop概率能够保留重要的特征信息,避免过度丢弃特征导致性能损失,串联特征使得特征得到了充分复用,高底层的特征融合增强了网络的抗过拟合性能,减少了参数,缓解了梯度消失问题。

附图说明

[0049] 图1为本发明流场预测方法的流程示意图。

具体实施方式

[0050] 下面结合附图和具体实施例对本发明的具体实施方式作进一步详细的说明。

[0051] 如图1所示,一种基于密集卷积网络的流场预测方法,包括以下步骤:

[0052] S1、获取翼型形状数据集及仿真流场数据集,并对翼型形状数据进行预处理,具体步骤如下:

[0053] S11、从翼型形状数据集中获取基准翼型并对其进行拟合,在拟合曲线上得到坐标细节;

[0054] S12、获取的坐标生成翼型的倒灰度图像,并在翼型轮廓完全通过的像素设置为1,在翼型轮廓没有通过的像素设置为0,其余像素值设置在0到1之间。

[0055] S2、利用加入自适应Dropout模块的密集卷积网络获取翼型几何参数,具体步骤如下:

[0056] S21、对于生成的翼型倒灰度图像 $X \in \mathbb{R}^{C \times H \times W}$,将其输入卷积层进行图像降维,其中, $\mathbb{R}$ 表示实数域, C 表示输入图像的通道数, H 和 W 表示特征图的高度和宽度;输出图像 $F \in \mathbb{R}^{C^{out} \times H^{out} \times W^{out}}$,其中 C^{out} 表示输出通道数, H^{out} 和 W^{out} 表示输出特征图的高度和宽度;

[0057] S22、卷积层的输出表示为 F 依次交替经过密集卷积网络的三个DenseBlock和两个Transition Layer(DenseBlock, Transition Layer, ..., DenseBlock)后进行池化和线性操作,得到翼型几何参数。

[0058] 所述步骤S22的具体步骤如下:

[0059] S221、卷积层的输出 F 进入DenseBlock中第一层Denselayer;

[0060] S222、Denselayer中的Batch Normalization Layer对其进行批归一化处理,得到归一化后的特征图 Y^{bn} ;

[0061] S223、通过激活函数SeLU(缩放指数线性单元)对特征图 Y^{bn} 进行逐元素操作修正,得到修正后的特征图 Y^{SeLU} ,SeLU函数计算公式如下:

$$[0062] \quad SeLU(x) = \begin{cases} \lambda x & x > 0 \\ \lambda \alpha e^x - \alpha x & x \leq 0 \end{cases}$$

[0063] S224、对修正后的特征图 Y^{SeLU} 进行 1×1 的卷积操作,得到卷积后的特征图 Y^{conv} ;

[0064] S225、特征图 Y^{conv} 再次经过Batch Normalization Layer和激活函数SeLU得到 $Y^{SeLU'}$,并对其进行 3×3 的卷积操作,得到特征图 $Y^{conv'}$;

[0065] S226、对于卷积后得到的特征图 $Y^{conv'}$ 进行自适应Drop,对其进行最大最小归一化得到 $Y^{(n)}$;使用伯努利分布Bernoulli(γ)进行随机采样,得到若干像素点 $M_{i,j}$,对于每个像素点 $M_{i,j}$,以其为中心设置一个大小为block_size $\times$ block_size的像素块,在每个像素块中,前 k 个百分位的元素设置为0,其余元素设置为1,进而生成一个模板 M , $Y'^{(n)}$ 的表达式如下:

$$[0066] \quad Y'^{(n)} = Y^{(n)} \times M$$

[0067] 再对 $Y'^{(n)}$ 进行缩放输出,其表达式如下:

$$[0068] \quad Y'^{(n+1)} = Y'^{(n)} \times \text{count}(M) \div \text{count_ones}(M)$$

[0069] 其中, $\text{count}(M)$ 表示模板 M 中元素的个数, $\text{count_ones}(M)$ 表示模板 M 中1的个数,block_size一般取值为3,5,7,若取值1的时候,算法会退化为传统的dropout模块, k 一般取值在30~50间; γ 表示控制需要Drop的特征数量,其表达式如下:

$$[0070] \quad \gamma = \frac{1 - \text{keep_prob}}{\text{block_size}^2} \cdot \frac{\text{feat_size}^2}{(\text{feat_size} - \text{block_size} + 1)^2}$$

[0071] 其中,keep_prob表示将单元块保留的概率;feat_size表示特征图大小;

[0072] S227、第一层Denselayer的输出 $Y'^{(n+1)}$ 依次输入到后续三层Denselayer中,且每一层Denselayer的输入均由前面所有Denselayer层输出的特征结合得到,其表达式如下:

$$[0073] \quad x_i = H_i([x_0, x_1, x_2 \dots x_{i-1}])$$

[0074] 其中, $x_0, x_1, x_2 \dots x_{i-1}$ 表示指在层 $0, 1 \dots, i-1$ 中产生特征图的串联, $H_i(\cdot)$ 函数表示 i 层Denselayer提取特征的过程;

[0075] S228、第四层Denselayer的输出,即第一个DenseBlock得到的特征图输入到Transition Layer,通过 1×1 的卷积核进行特征通道降维,再通过 2×2 平均池化层进行特征下采样;并继续输入到接下来的DenseBlock、Transition Layer及DenseBlock;

[0076] S229、从最后一个Denseblock模块输出的特征图 Y ,经过池化层和线性层得到翼型特征参数 P 。

[0077] S3、构建翼型参数和物理参数输入用例,具体方法如下:

[0078] 将由密集卷积网络得到的特征参数 P ,结合翼型控制点坐标 (x, y) 以及雷诺数 (Re) 和攻角 (AOA) 结合组成输入用例,与CFD模拟仿真的流场数据构建训练流场预测模型的数据集。

[0079] S4、训练基于MHP的流场预测模型,具体步骤如下:

[0080] S41、将步骤S2中得到的翼型特征参数和步骤S3中构建的物理特征作为输入,对模型进行训练,利用多头网络得到模型对不同分布特征的物性参数 (u, p, v) 的预测输出,其具体表达式如下:

$$[0081] \quad \begin{cases} f_{MHP-U(I, Re, AOA, x, y)} = u \\ f_{MHP-P(I, Re, AOA, x, y)} = p \\ f_{MHP-V(I, Re, AOA, x, y)} = v \end{cases}$$

[0082] 其中,公式左侧表示MHP的预测模型, u, p, v 分别表示流场的 x 方向速度分量,压力值和 y 方向速度分量;

[0083] S42、多头感知机中每头的LOSS函数表达式如下:

$$[0084] \quad \begin{cases} MHP(u)_{loss} = \frac{1}{N} \sum_{i=1}^N (u_i^t - u_i^p)^2 \\ MHP(p)_{loss} = \frac{1}{N} \sum_{i=1}^N (p_i^t - p_i^p)^2 \\ MHP(v)_{loss} = \frac{1}{N} \sum_{i=1}^N (v_i^t - v_i^p)^2 \end{cases}$$

[0085] 其中, u_i^t 、 p_i^t 、 v_i^t 分别表示由CFD模拟的流场 x 方向速度分量,压力值和 y 方向速度分量, u_i^p 、 p_i^p 、 v_i^p 分别表示预测值;

[0086] S43、当LOSS收敛时,训练结束,得到预测模型。

[0087] S5、利用训练好的流场预测模型(MHP网络),输入不同翼型数据(翼型特征、攻角、雷诺数)预测流场。

[0088] 以上所述仅是本发明的实施方式,再次声明,对于本技术领域的普通技术人员来说,在不脱离本发明原理的前提下,还可以对本发明进行若干改进,这些改进也列入本发明权利要求的保护范围内。




图1