



(12) 发明专利申请

(10) 申请公布号 CN 118349774 A

(43) 申请公布日 2024. 07. 16

(21) 申请号 202410409395.4

G06N 20/00 (2019.01)

(22) 申请日 2024.04.07

G06N 3/048 (2023.01)

(71) 申请人 中国核动力研究设计院

G06F 18/214 (2023.01)

地址 610213 四川省成都市双流区长顺大道一段328号

G06F 18/25 (2023.01)

(72) 发明人 刘东 安萍 江勇 张斌 彭航
陈长 李庆 卢宗健 刘艳阳
芦韡 潘俊杰 杨戴博 曾辉
肖聪 汤琪芬 曹洪 李治刚
刘婷 张虎 李昆

(74) 专利代理机构 核工业专利中心 11007
专利代理师 陈丽丽

(51) Int. Cl.

G06F 17/13 (2006.01)

G06F 17/18 (2006.01)

权利要求书2页 说明书10页 附图4页


(54) 发明名称

一种基于深度学习驱动的反应堆堆芯功率重构方法

(57) 摘要

本发明属于核反应堆堆芯计算技术领域,具体涉及一种基于深度学习驱动的反应堆堆芯功率重构方法,步骤如下:将神经网络函数代入中子扩散方程的数理方程,构建控制方程形成的损失函数、边界条件形成的损失函数,根据数据样本点构建数据表示的损失函数;对控制方程形成的损失函数、边界条件形成的损失函数、数据表示的损失函数分别赋值权重并进行加合,得到统一的机器学习损失函数;通过深度学习技术,迭代优化神经网络函数中的神经网络连接权重和神经网络偏置项,逐步减小统一的机器学习损失函数的值到精度范围内;同时神经网络函数输出逼近了系统定义域通量密度的数值解,得到逆向求解中子扩散方程的近似数值解,实现反应堆堆芯功率重构。本发明方法基于深度学习方法和数据驱动融合进行中子扩散数理方程逆向求解,可通过调整边界条件形成的约束损失函数权重实

现一定的边界误差容错功能,同时对数据样本数量及空间分布具有较强包容性,可实现高精度、高效率、高鲁棒性的反应堆功率重构计算。



1. 一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述方法包括:

步骤1:将神经网络函数代入中子扩散方程的数理方程,构建控制方程形成的损失函数、边界条件形成的损失函数,根据数据样本点构建数据表示的损失函数;对控制方程形成的损失函数、边界条件形成的损失函数、数据表示的损失函数分别赋值权重并进行加合,得到统一的机器学习损失函数;

步骤2:通过深度学习技术,迭代优化神经网络函数中的神经网络连接权重和神经网络偏置项,逐步减小统一的机器学习损失函数的值到精度范围内;同时神经网络函数输出逼近了系统定义域通量密度的数值解,得到逆向求解中子扩散方程的近似数值解,实现反应堆堆芯功率重构。

2. 根据权利要求1所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述边界条件形成的损失函数的边界条件包括:非负边界、真空边界、零边界、反射边界、瞬态计算初始状态。

3. 根据权利要求1所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述数据表示的损失函数的数据来源包括:在线的堆芯中子探测器实测数据、正向求解方程理论解和不同批次的历史实测数据或特定实验数据。

4. 根据权利要求1所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述步骤1还包括:对得到的统一的机器学习损失函数进行修正。

5. 根据权利要求4所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述对得到的统一的机器学习损失函数进行修正包括:

步骤1.5.1:调整边界条件形成的损失函数的权重,进行边界缺失修正;

步骤1.5.2:调整数据表示的损失函数,进行多源数据加权融合;

步骤1.5.3:调整故障探测器的测量数据,进行探测器故障修正;

步骤1.5.4:调整控制方程形成的损失函数,进行材料特性参数修正。

6. 根据权利要求5所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述步骤1.5.1具体为:通过调整边界条件形成的损失函数的权重,实现一定的边界误差容错功能,当边界条件复杂、相关截面参数误差较大时,减小边界条件形成的约束损失函数的权重,消除边界条件对整体机器学习结果的影响。

7. 根据权利要求6所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,无边界条件的极端情况下,可不考虑边界条件,仅利用由数据表示的损失函数和控制方程形成的损失函数进行机器学习。

8. 根据权利要求5所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述步骤1.5.3具体为:当探测器测量数据缺少情况下,采用故障探测器的历史数据或者该故障探测器周围状态良好的探测器数据平均值进行替代,实现精准计算。

9. 根据权利要求5所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述步骤1.5.3具体为:当探测器损坏情况下,可直接忽略该探测器的数据来源,采用其余探测器数据作为该类样本数据。

10. 根据权利要求5所述的一种基于深度学习驱动的反应堆堆芯功率重构方法,其特征在于,所述步骤1.5.4具体为:将材料特性参数作为目标估计参数,将目标估计参数与神经网络连接权值一并设定为可调整优化变量,生成了由神经网络函数与目标估计参数共同构

成的残差,作为控制方程的机器学习损失函数,然后在统一的框架内进行进一步的机器学习,在神经网络函数权重输出中子扩散方程的近似数值解的同时,优化后的各项材料特性参数就是目标估计值。

一种基于深度学习驱动的反应堆堆芯功率重构方法

技术领域

[0001] 本发明属于核反应堆堆芯计算技术领域,具体涉及一种基于深度学习驱动的反应堆堆芯功率重构方法。

背景技术

[0002] 对反应堆堆芯的三维功率分布进行在线监测,以保证相关安全参数不超出设计限值,对预测并防止各种事故发生有重要意义,也可为堆芯功率的负荷跟踪、启动和停堆等特定控制提供必要的输入,这是保证反应堆运行安全性、提升反应堆经济性的重要手段。

[0003] 当前,堆芯在线功率监测是通过中子探测器的测量,进而基于理论计算进行堆芯三维分布功率重构实现的。由于反应堆堆芯探测空间有限并且处于高温高压的复杂辐射环境中,中子探测器只能实现对部分组件进行测量,无法直接测量堆芯所有组件的功率分布。实际工程中均根据有限数量的堆内、堆外中子探测器的读数进行功率分布重构理论计算来间接获取全部堆芯实测功率分布。图1为典型压水堆堆芯监测与三维堆芯功率重构原理图。

[0004] 与正向求解中子物理方程直接通过完整的控制方程形式、边界条件获得堆芯通量密度分布不同,重构堆芯功率分布的任务是在中子物理方程的各种截面、边界条件等存在一定误差或者缺失下,利用实际测量到的小样本、具有一定误差的数据,通过理论计算重构出通量密度分布,从而得到堆芯功率分布,数理上这是一个逆向求解中子物理方程的过程。

[0005] 经典的功率重构方法包括插值类方法和谐波类方法,这些方法已经在研究与工程应用上取得了显著的成果。与此同时,这些传统方法在计算精度、效率、鲁棒性方面也存在一定的不足与挑战,需要新的技术路线进一步提升性能。

[0006] 目前,工程上大型反应堆堆芯功率重构的理论计算主要基于中子扩散方程。随着新一代人工智能技术的快速发展,以深度学习为代表的智能技术在正向求解复杂微分方程上取得了重要的突破,但结合数据驱动逆向求解反应堆中子扩散方程领域缺少系统研究。这种方法在求解高维复杂空间、数据融合与同化、计算规范性等方面表现出一定的潜在优势,为反应堆的堆芯功率重构方法提供了一条新的技术思路。

发明内容

[0007] 本发明的目的在于提供一种基于深度学习驱动的反应堆堆芯功率重构方法,该方法基于深度学习方法和数据驱动融合进行中子扩散数理方程逆向求解,可通过调整边界条件形成的约束损失函数权重实现一定的边界误差容错功能,同时对数据样本数量及空间分布具有较强包容性,可实现高精度、高效率、高鲁棒性的反应堆功率重构计算。

[0008] 实现本发明目的的技术方案:

[0009] 一种基于深度学习驱动的反应堆堆芯功率重构方法,所述方法包括:

[0010] 步骤1:将神经网络函数代入中子扩散方程的数理方程,构建控制方程形成的损失函数、边界条件形成的损失函数,根据数据样本点构建数据表示的损失函数;对控制方程形成的损失函数、边界条件形成的损失函数、数据表示的损失函数分别赋值权重并进行加合,

得到统一的机器学习损失函数;

[0011] 步骤2:通过深度学习技术,迭代优化神经网络函数中的神经网络连接权重和神经网络偏置项,逐步减小统一的机器学习损失函数的值到精度范围内;同时神经网络函数输出逼近了系统定义域通量密度的数值解,得到逆向求解中子扩散方程的近似数值解,实现反应堆堆芯功率重构。

[0012] 进一步地,所述边界条件形成的损失函数的边界条件包括:非负边界、真空边界、零边界、反射边界、瞬态计算初始状态。

[0013] 进一步地,所述数据表示的损失函数的数据来源包括:在线的堆芯中子探测器实测数据、正向求解方程理论解和不同批次的历史实测数据或特定实验数据。

[0014] 进一步地,所述步骤1还包括:对得到的统一的机器学习损失函数进行修正。

[0015] 进一步地,所述对得到的统一的机器学习损失函数进行修正包括:

[0016] 步骤1.5.1:调整边界条件形成的损失函数的权重,进行边界缺失修正;

[0017] 步骤1.5.2:调整数据表示的损失函数,进行多源数据加权融合;

[0018] 步骤1.5.3:调整故障探测器的测量数据,进行探测器故障修正;

[0019] 步骤1.5.4:调整控制方程形成的损失函数,进行材料特性参数修正。

[0020] 进一步地,所述步骤1.5.1具体为:通过调整边界条件形成的损失函数的权重,实现一定的边界误差容错功能,当边界条件复杂、相关截面参数误差较大时,减小边界条件形成的约束损失函数的权重,消除边界条件对整体机器学习结果的影响。

[0021] 进一步地,无边界条件的极端情况下,可不考虑边界条件,仅利用由数据表示的损失函数和控制方程形成的损失函数进行机器学习。

[0022] 进一步地,所述步骤1.5.3具体为:当探测器测量数据缺少情况下,采用故障探测器的历史数据或者该故障探测器周围状态良好的探测器数据平均值进行替代,实现精准计算。

[0023] 进一步地,所述步骤1.5.3具体为:当探测器损坏情况下,可直接忽略该探测器的数据来源,采用其余探测器数据作为该类样本数据。

[0024] 进一步地,所述步骤1.5.4具体为:将材料特性参数作为目标估计参数,将目标估计参数与神经网络连接权重一并设定为可调整优化变量,生成了由神经网络函数与目标估计参数共同构成的残差,作为控制方程的机器学习损失函数,然后在统一的框架内进行进一步的机器学习,在神经网络函数权重输出中子扩散方程的近似数值解的同时,优化后的各项材料特性参数就是目标估计值。

[0025] 本发明的有益技术效果在于:

[0026] 1、利用本发明提供的一种基于深度学习驱动的反应堆堆芯功率重构方法进行堆芯功率重构计算时,能够有效减少探测器布置方式对于计算功率重构的精度影响。

[0027] 2、本发明提供的一种基于深度学习驱动的反应堆堆芯功率重构方法,通过调整数据权重,能够有效利用来源不同、精度不同的数据。

[0028] 3、当探测器出现故障,利用本发明提供的一种基于深度学习驱动的反应堆堆芯功率重构方法,仍能以较高精度得出功率重构结果,减少数据缺失对堆芯重构影响,具有一定的鲁棒性。

[0029] 4、本发明提供的一种基于深度学习驱动的反应堆堆芯功率重构方法,实现了对方

程中截面参数修正与估计,可有效减少参数误差给逆向求解方程带来的影响。这对于解决当前各种传统功率重构方法面临的因燃烧等因素带来截面变化,进而影响功率重构精度的问题,具有重要的潜在应用价值。

[0030] 5、本发明提供一种基于深度学习驱动的反应堆堆芯功率重构方法,能够在没有边界条件情况下,只结合少量数据以及控制方程,即可实现深度学习逆向驱动求解中子双群扩散方程,计算的功率重构结果具有良好的精度。

附图说明

[0031] 图1为典型压水堆堆芯监测及三维堆芯功率重构原理图,其中,图1a为堆芯径向探测组件布置示意图,图1b为三维堆芯功率重构原理图;

[0032] 图2为本发明实施例2中探测器布置图;

[0033] 图3为本发明实施例2中数据精度对求解结果的影响图;

[0034] 图4为本发明实施例2中数据权重对MSE1影响图;

[0035] 图5为本发明实施例2中探测器故障对MSE1影响图;

[0036] 图6为本发明实施例3中堆芯探测器布置示意图,其中,图6a为堆芯径向布置示意图,图6b为堆芯轴向分层示意图;

[0037] 图7为本发明实施例3中训练集探测器与测试集探测器分布图;

[0038] 图8为本发明实施例3中神经网络输出的通量密度分布图,其中,图8a为快群网络输出通量分布图,图8b为热群网络输出通量分布图。

具体实施方式

[0039] 下面结合附图和实施例对本发明作进一步详细说明。

[0040] 本发明提供一种基于深度学习驱动的反应堆堆芯功率重构方法,基于深度学习技术,利用人工神经网络的“万能逼近”性质,在中子扩散方程的数理形式具有一定的误差甚至缺失情况下,融合方程物理模型与小样本测量数据信息,利用机器学习原理无限逼近微分方程,获得深度神经网络表示的方程数值解,从而实现逆向求解中子扩散方程。同时,构建逆向求解中子扩散方程与堆芯功率重构机器学习系统框架,掌握边界条件缺失处理、数据融合、探测器故障修正等多项功率重构关键技术,并通过标准例题进行原理性验证,为研制出高精度、高效率、高鲁棒性的反应堆功率重构方法探索新的技术道路。

[0041] 实施例1

[0042] 本发明提供一种基于深度学习驱动的反应堆堆芯功率重构方法,具体包括以下步骤:

[0043] 步骤1:将L层神经网络函数代入中子扩散方程的数理方程,构建控制方程形成的损失函数、边界条件形成的损失函数,根据数据样本点构建数据表示的损失函数;对控制方程形成的损失函数、边界条件形成的损失函数、数据表示的损失函数分别赋值权重并进行加合,得到统一的机器学习损失函数;

[0044] 中子扩散方程的完整形式如下:

$$\begin{aligned}
[0045] \quad \frac{1}{v} \frac{\partial \phi(r, E, t)}{\partial t} = \nabla \cdot D \nabla \phi(r, E, t) - \Sigma_t(r, E) \phi(r, E, t) \\
+ x(E) \int_0^\infty \vartheta(E') \Sigma_f(r, E') \phi(r, E', t) dE' \\
+ \int_0^\infty \Sigma_s(r, E' \rightarrow E) \phi(r, E', t) dE' + S(r, E, t) \quad (1)
\end{aligned}$$

[0046] 式中, $\phi(r, E, t)$ 是 t 时刻在 r 位置处能量为 E 的中子通量密度, v 为中子速率, D 为中子扩散系数, θ 为每次裂变放出的平均中子数, $x(E)$ 是裂变中子的能谱分布, Σ_t 、 Σ_s 和 Σ_f 分别是总的反应截面、散射截面和裂变截面, $S(r, E, t)$ 为外源。

[0047] 中子扩散方程的数理方程形式为:

$$[0048] \quad F[\vec{x}, \phi(\vec{x}), \nabla \phi(\vec{x}), \nabla^2 \phi(\vec{x})] = 0 \quad (2)$$

[0049] 式中, $\vec{x}$ 表示关于 (r, E, t) 的向量, $\phi(\vec{x})$ 为中子通量密度。

[0050] L 层神经网络函数形式为:

$$[0051] \quad N^l(\vec{x}) = f^l(w^l f^{l-1}(w^{l-1}(f^{l-2}(\dots f^1(w^1 \vec{x} + b^1) + b^2) \dots + b^l) \quad (3)$$

[0052] 式中, w 为神经网络连接权重, b 为神经网络偏置项, l 为神经网络的层数编号, $N^l(\vec{x})$ 为神经网络输出函数, w^1 为第 1 层神经网络连接权重, b^1 为第 1 层神经网络偏置项, f^1 为第 1 层神经网络激活函数, $\vec{x}$ 为神经网络向量。将 (3) 式作为试函数代入 (2) 式, 构建统一的机器学习损失函数。

[0053] 步骤 1.1: 将 L 层神经网络函数代入中子扩散方程的数理方程, 构建控制方程形成的损失函数;

[0054] 令 $N(\vec{x}) = \phi(\vec{x})$, 其中, 神经网络向量 $\vec{x}$ 表示方程空间几何变量, $\vec{x}$ 可根据扩散方程的维度做适应性调整, 则由 (2) 式得到控制方程形成的损失函数 F_{Loss_f} 为:

$$[0055] \quad F_{\text{Loss}_f} = \frac{1}{I} \sum_{i=1}^I F[\vec{x}^i, N(\vec{x}^i), \nabla N(\vec{x}^i), \nabla^2 N(\vec{x}^i)]^2 \quad (4)$$

[0056] 其中, i 为机器学习所需要的样本点, 可按照一定的概率密度分布生成, 或者根据方程的形式采用不同密度分布策略生成。

[0057] 步骤 1.2: 将 L 层神经网络函数代入中子扩散方程的数理方程, 构建边界条件形成的损失函数;

[0058] 设 $\phi(\vec{x})$ 定义域中 $\vec{x}_b \in \Gamma_b$ 为方程的几何边界域, 用 $\vec{x}_b^j$ 表示边界上样本点 j 几何向量, $N(\vec{x}_b^j)$ 表示边界处神经网络输出值, $K_b(\vec{x}_b^j)$ 表示中子扩散方程实际定义的边界条件, 则得神经网络函数表示的边界条件形成的损失函数 F_{Loss_b} 为:

$$[0059] \quad F_{\text{Loss}_b} = \frac{1}{J} \sum_{j=1}^J [N(\vec{x}_b^j) - K_b(\vec{x}_b^j)]^2 \quad (5)$$

[0060] 式中 $K_b(\vec{x}_b^j)$ 取值方式由边界条件形式确定, 常用的边界条件包括非负边界、真空边界、零边界、反射边界、瞬态计算初始状态等。

[0061] 步骤1.3:根据数据样本点构建数据表示的损失函数;

[0062] 用 $\vec{x}_{data}^m$ 表示监测数据样本点m几何空间向量,用 $N(\vec{x}_{data}^m)$ 表示监测点神经网络输出值,用 $\vec{y}_{data}^m$ 表示相应位置的通量密度值,数据点m可来自中子探测器测量当前/历史测量数据、数值计算理论数据等,则得到数据表示的损失函数 F_{Loss_data} 为:

$$[0063] \quad F_{Loss_data} = \frac{1}{M} \sum_{m=1}^M [N(\vec{x}_{data}^m) - \vec{y}_{data}^m]^2 \quad (6)$$

[0064] 由数据表示的损失函数的数据来源包括:采用已有软件计算的理论数据,对应方程的解析解,由堆芯探测器测量的对应位置的电流信号、不同批次的历史实测数据或特定实验数据,再由电流信号转化为对应位置的分群中子注量率。

[0065] 步骤1.4:将步骤1.1-1.3构建的三类损失函数分别赋值权重并进行加合(加权),得到统一的机器学习损失函数;

[0066] 将步骤1.1-1.3的三类损失函数加权,得到统一的机器学习损失函数 F_{Loss_all} 为:

$$[0067] \quad F_{Loss_all} = P_f \cdot F_{Loss_f} + P_b \cdot F_{Loss_b} + P_{data} \cdot F_{Loss_data} \quad (7)$$

[0068] P_f, P_b, P_{data} 分别为控制方程形成的损失函数的权重、边界条件形成的损失函数的权重、数据表示的损失函数的权重。

[0069] 步骤1.5:对得到的统一的机器学习损失函数进行修正

[0070] 步骤1.5.1:调整边界条件形成的损失函数的权重,进行边界缺失修正

[0071] 在实际反应堆工程堆芯的中子扩散方程求解任务中,由于堆芯外围吊篮围板、筒体、上下支撑等结构部件复杂性,方程的边界条件精确描述是困难的,方程中反射层各种截面参数的取值常常会具有较大的误差,堆芯几何结构越复杂,这种现象越为明显,这也是逆向求解中子扩散方程重构堆芯功率要面临的重要挑战,需要适合的方法进行处理。

[0072] 如公式(7)所示,深度学习逆向求解扩散方程的损失函数组成包含了控制方程、边界条件、实测数据的因素,这种方法本身具有融合物理模型与数据驱动的特性。基于此,可以通过调整损失函数权重的方式来修正边界条件引起的误差,实现一定的边界误差容错功能。

[0073] 当边界条件复杂、相关截面参数误差较大时,减小 P_b 值来消除边界条件对整体机器学习结果的影响。极端条件下,甚至可以令 $P_b = 0$,相当于不计入反射层形成的边界条件几何形式与数理特性,仅利用实测数据表示的损失函数及控制方程形成的损失函数进行机器学习,可有效减小边界条件误差带来的影响,这是深度学习驱动逆向求解中子扩散方程的重要特性与优势。

[0074] 步骤1.5.2:调整数据表示的损失函数,进行多源数据加权融合

[0075] (6) 式中功率重构所需要的数据来源,可以包括当前在线堆芯中子探测器实测数据,也可包括传统方法中子扩散计算软件正向求解方程获得的数值计算数据,甚至是不同批次的历史实测数据或特定实验数据。这些数据往往具有不同精度、空间分布、数据量大小特性,应根据不同的数据特性与系统功率需求,选取恰当的权重,加权构成数据驱动损失函数,从而实现数据融合与模型同化。即将(6)式变为:

$$[0076] \quad F_{\text{Loss_data}} = \sum_{n=1}^Q \frac{P_n}{q} \sum_{n_m=1}^q (N(\vec{x}_{\text{data}}^{n_m}) - \vec{Y}_{\text{data}}^{n_m})^2 \quad (8)$$

[0077] 其中, n 为每种不同来源数据类型, n_m 为该数据来源类型的样本点, P_n 为该数据来源权重, q 为该来源数据数量, Q 为不同数据来源类型集合的模。数据来源类型越准确、越完整, 相应的 P_n 取值应越大。

[0078] 步骤1.5.3: 调整故障探测器的测量数据, 进行探测器故障修正

[0079] 反应堆的中子探测器安装在高温、高压、高强辐射环境中, 探测器测量具有一定的误差, 并有发生故障的风险。与此同时, 由于换料周期等原因, 失效后并不能及时进行替换, 存在一定时间故障探测器伴随堆芯运行的可能, 需要功率重构方法具有一定的鲁棒性, 尽可能减小中子探测器设备故障带来的影响。

[0080] 由于深度学习方法逆向求解中子扩散方程具有融合物理模型与数据驱动信息的固有特性, 少量测量数据缺失对堆芯功率重构的影响性较小, 系统本身具有一定的鲁棒性。出现探测器故障时, 仅仅需要将这些故障探测器的测量数据简单移除, 系统仍然具有一定的精度。即当个别探测器损坏情况下, 可直接忽略该探测器的数据来源, 采用其余探测器数据作为该类样本数据。

[0081] 此外, 也可采用故障探测器的历史数据或者该故障探测器周围状态良好的探测器数据平均值进行替代。即当个别探测器测量数据缺少情况下, 采用故障探测器的历史数据或者该故障探测器周围状态良好的探测器数据平均值进行替代, 可以实现精准计算。

[0082] 步骤1.5.4: 调整控制方程形成的损失函数, 进行材料特性参数修正

[0083] 反应堆运行过程中, 由于功率水平、燃耗深度均不断发生变化, 这造成了中子扩散方程中的各项材料扩散系数、各种截面参数会持续发生改变, 难以获得探测器测量时刻精确的参数, 这是逆向求解中子扩散方程面临的重要问题与挑战, 存在对带有误差的方程参数进行重新估计与修正的需求。

[0084] 可行的参数估计与修正方式是将目标估计参数与神经网络连接权值一并设定为可调整优化变量, 共同进行深度学习优化, 即将公式 (4) 变为:

$$[0085] \quad F_{\text{Loss_f}} = \frac{1}{I} \sum_{i=1}^I F[\vec{x}^i, N(\vec{x}^i), \nabla N(\vec{x}^i), \nabla^2 N(\vec{x}^i), \Sigma_x]^2 \quad (9)$$

[0086] 式中 Σ_x 表示中子扩散方程中待估计修正的材料特性参数, 如扩散系数、各种宏观截面参数等。(9) 式生成了由神经网络函数与被估计参数共同构成的残差, 作为加权机器学习损失函数 (7) 的组成部分, 然后在进行进一步的机器学习, 神经网络函数逼近中子扩散方程近似数值解的同时, 也实现了截面参数的修正与估计。

[0087] 材料特性参数包括吸收、裂变、散射等截面参数, 可将某一计算网格某种特定截面参数设定为调整优化变量, 与神经网络函数共同构成的残差, 作为控制方程的机器学习损失函数, 然后在统一的框架内进行进一步的机器学习, 在神经网络函数权重输出中子扩散方程的近似数值解的同时, 优化后的单一截面参数就是目标估计值。

[0088] 步骤2: 通过深度学习技术, 迭代优化神经网络函数中的神经网络连接权重和神经

网络偏置项,逐步统一的机器学习损失函数的值到精度范围内;同时神经网络函数输出逼近了系统定义域通量密度的数值解,得到逆向求解中子扩散方程的近似数值解,实现反应堆堆芯功率重构;

[0089] 机器学习过程是优化调整(3)式中的神经网络连接权重 w^1 与神经网络偏置项 b^1 ,使得统一的机器学习损失函数 F_{Loss_all} 的值趋近于0,此时神经网络输出 $\vec{Y} = N(\vec{x})$ 趋近于 $\phi(\vec{x})$ 。实践中设定合理的 ϵ ,当 F_{Loss_all} 小于 ϵ ,停止学习迭代,此时神经网络函数的输出 $N(\vec{x})$ 就是逆向求解扩散方程得到的近似数值解,得到空间连续通量密度的数值解,实现反应堆堆芯功率重构。

[0090] 实施例2单群临界验证

[0091] 问题描述:临界条件下,立方体几何单群单材料区域问题方程形式为:

$$\begin{aligned} [0092] \quad & \frac{\partial^2 \phi(x, y, z)}{\partial x^2} + \frac{\partial^2 \phi(x, y, z)}{\partial y^2} + \frac{\partial^2 \phi(x, y, z)}{\partial z^2} \\ & + [(\pi/a)^2 + (\pi/b)^2 + (\pi/c)^2]^2 \phi(x, y, z) = 0 \end{aligned} \quad (10)$$

[0093] 设定堆芯长 $a=3.4\text{m}$,宽 $b=3.4\text{m}$,高 $c=4.2\text{m}$ 。边界条件为: $\phi(\pm a/2, \pm b/2, \pm c/2) = 0$,其几何曲率 $B_g^2 = [(\pi/a)^2 + (\pi/b)^2 + (\pi/c)^2]^2$,立方体堆芯通量密度解析解为: $C \cdot \cos(x \cdot \pi/a) \cos(y \cdot \pi/b) \cos(z \cdot \pi/c)$ 。 C 为任意固定非零实数,此处取 $C=0.5$ 。

[0094] 仿真模拟当前压水堆探测器布置如图2所示,沿 z 轴轴线分为7层,每层间隔 0.6333m ,以反应堆中心为中心对称布置,共308个探测器点。中子探测器的值由该位置的解析解进行仿真确定。

[0095] 神经网络设置 $n=20$, $l=24$,激活函数选用 $\tanh$,网络初始值高斯随机分布,机器采样点14000,定义域内随机分布,采用ADAM机器学习算法;机器学习率从 $1e-4$ 开始,随着学习次数增加,逐渐下降到 $5e-7$,直到损失函数平稳,在100次迭代内变化率小于0.0001。验证工作式(7)中,均取 $P_f=1$ 。

[0096] 边界缺失情况下的数值验证

[0097] 为了探究边界条件以及探测器布置方式对于计算结果的影响,设置以下实验:

[0098] 探测器布置方式采用两种,固定布置如图2所示,随机布置即在立方体内随机取308个点。机器学习方法均迭代30000次。并且当边界条件缺失时,取 $P_b=0$,当边界条件存在时 $P_b=15$,均取 $P_{data}=15$,实验结果如表1所示。

[0099] 表1临界条件下稳态扩散方程计算结果

[0100]	探测器布置方式	边界条件	MSE_1	SE_{imax}	F_{Loss_all}
	随机布置	缺失	2.3113e-05	2.2555e-03	7.4933e-04
	固定布置	缺失	4.9489e-05	1.5108e-03	5.3196e-04
	随机布置	存在	1.2899e-05	3.6196e-03	1.3334e-03
	固定布置	存在	8.4816e-06	3.3204e-03	1.6183e-03

[0101] 其中, MSE_1 为学习好的神经网络函数 $N(\vec{x})$ 在所有探测器点上泛化计算结果与解析解的均方差; SE_{imax} 为探测器点集合中每个点处的 $N(\vec{x})$ 与解析解的方差最大值, F_{Loss_all}

为模型训练完成时的损失函数。

[0102] 从实验看出,探测器布置方式对于计算精度影响不大;边界条件存在与否对于计算精度虽然有一定影响,但影响不明显,即不考虑边界条件的约束,利用深度学习驱动逆向求解中子扩散方程仍然具有较好的精度。该特性表明:在实际工程中,如果边界条件描述与相关截面参数具有较大的误差,可以采用不考虑边界条件的策略,对功率重构的精度影响不大。

[0103] 数据融合方法与同化策略验证

[0104] 为了模拟精度不同、来源不同的数据对精度的影响,及其数据融合方法策略验证,设计如下实验:

[0105] (1) 通过对固定布置探测器点的解析解添加少量误差,以此来模拟式(12)中用于功率重构的,精度不同、来源不同的数据对功率重构结果影响

[0106] 将探测器点等分为两部分,一半数据点取解析解,不做处理,其权重取为 $P_1=50$,另一半数据点添加不同大小误差(40%,30%,20%,15%,10%),其权重均取为 $P_2=50$,不添加边界条件,机器学习均迭代20000次,实验结果如表2、图3所示。

[0107] 表2数据误差对临界条件下单群扩散方程求解结果影响

[0108]

添加误差量	MSE_1	SE_{imax}	F_{Loss_all}
40%	4.7356e-04	0.2519	4.4742e-02
30%	3.3383e-04	0.3056	3.3169e-02
20%	9.3786e-05	0.1002	1.6849e-02
15%	6.2666e-05	0.0721	1.1364e-02
10%	3.5462e-05	0.0539	5.8710e-03

[0109] (2) 对不同精度的数据调整权重 P_n ,构成加权数据驱动损失函数,测试其对模型同化性能的影响。

[0110] 将探测器点等分为两部分,一半数据点取解析解,不做处理,其权重取为 P_1 ,另一半数据点添加10%误差,其权重取为 P_2 ,调整两部分数据损失函数权重,共设5次实验, (P_1 , P_2) 取值分别为(30,70), (40,60), (50,50), (60,40), (70,30), 均不添加边界条件,机器学习均迭代20000次,实验结果如表3、图4所示。

[0111] 表3数据权重对临界条件下单群扩散方程求解影响

[0112]

$P_1:P_2$	MSE_1	SE_{imax}	F_{Loss_all}
3:7	5.9282e-05	0.1068	6.2941e-03
4:6	4.8120e-05	0.0667	6.6650e-03
5:5	3.5462e-05	0.0539	5.8710e-03
6:4	3.3228e-05	0.0647	5.3124e-03
7:3	2.9803e-05	0.0517	4.2721e-03

[0113] 通过实验可得:当来源数据精度分布不同,可通过对不同来源数据加权带入损失函数,实现数据融合与模型同化,并且对于精度越高的数据,赋予更大的权重 P_n ,可使计算结果精度更高,权重比值到达一定值,趋于稳定。对于实际工程中很难获得完全准确的数据,该方法可调整数据权重,有效利用来源不同、精度不同的数据。

[0114] 探测器故障修正方法验证

[0115] 实际工程中,探测器有发生故障的风险,为了探究探测器故障后,对本文方法的鲁棒性影响,设计了以下实验:

[0116] 探测器仍采用固定位置布置,随机去除一定百分比的探测点数据(50%,30%,15%,10%,5%),模拟探测器故障后移除,其余探测点数据为解析解,权重 P_{data} 均取50,均不添加边界条件,仿真探测器故障数量对于实验结果影响。机器学习均迭代15000次,实验结果如表4、图5所示。

[0117] 表4探测点故障对临界条件下单群扩散方程求解影响

[0118]	探测器故障率	MSE_1	SE_{imax}	F_{Loss_all}
	50%	8.0852e-05	3.2002e-03	1.0043e-03
	30%	4.8795e-05	1.2774e-03	8.6969e-04
	15%	4.3712e-05	9.4447e-04	1.3046e-03
	10%	3.9350e-05	3.9371e-03	1.2621e-03
	5%	3.2369e-05	2.6231e-03	9.3367e-04

[0119] 表明当探测器出现故障,本文方法仍能以较高精度得出结果,少量数据缺失对堆芯重构影响不大,本方法具有一定的鲁棒性。这种特性对于实际工程中防范探测器损坏带来的潜在风险具有良好修正效果。

[0120] 材料特性参数的估计修正方法验证

[0121] 为验证本文材料特性参数的估计修正方法,设计以下实验:

[0122] 立方体几何单群单材料区域问题方程如式(10),当反应堆达到临界状态,材料曲率等于几何曲率,即 $B_m^2 = B_g^2$,又因为 $B_m^2 = \frac{k_\infty - 1}{L^2}$, $L^2 = D / \Sigma_a$,所以式(10)可变为:

$$\frac{\partial^2 \phi(x, y, z)}{\partial x^2} + \frac{\partial^2 \phi(x, y, z)}{\partial y^2} + \frac{\partial^2 \phi(x, y, z)}{\partial z^2} + \frac{k_\infty - 1}{D} \cdot \Sigma_a \cdot \phi(x, y, z) = 0 \quad (11)$$

[0124] 设 $\Sigma_a = 1.0000$ 为该问题的标准值,通过给 Σ_a 添加误差,变为 Σ'_a 带入到式(11),通过深度学习进行方程求解,将神经元权重与带有误差的 Σ'_a 作为优化参数,同时针对 F_{Loss_all} 进行修正,在损失函数逼近0的同时, Σ'_a 逼近标准值 $\Sigma_a = 1$ 。探测器采用固定位置布置,不添加边界条件,神经网络设置 $n=25$, $l=10$,权重 $P_{data}=50$,实验结果如表5所示。

[0125] 表5材料特性参数修正方法验证结果

[0126]	Σ_a 标准值	修正前的 Σ'_a 值	修正前与 Σ_a 的相对误差	修正后的 Σ'_a 值	修正后与 Σ_a 的相对误差	MSE_1	SE_{imax}	F_{Loss_all}
	1.0000	1.2000	20.00%	0.9656	3.44%	5.4740e-05	1.7384e-03	1.2937e-03
		1.2500	25.00%	0.9558	4.42%	6.1001e-05	1.4135e-03	1.2192e-03
		1.3000	30.00%	0.9443	5.57%	9.4213e-05	1.6619e-03	3.2641e-03
		1.4000	40.00%	0.9506	4.94%	8.3828e-05	1.1057e-03	2.3701e-03

[0127] 从实验可以看出,利用深度学习驱动逆向求解中子扩散方程,可实现了对方程中截面参数修正与估计,可有效减少参数误差给逆向求解方程带来的影响。这对于解决当前各种传统功率重构方法面临的因燃耗等因素带来截面变化,进而影响功率重构精度的问题,具有重要的潜在应用价值。

[0128] 实施例3堆芯功率重构仿真案例验证

[0129] 以下以具有一定工程背景堆芯案例为对象进行仿真验证,假设具有177组燃料组件的堆芯被均匀分为28层,每层探测器布置均如图6所示,X表示该位置布置有探测器,每个组件都为正方形,假定每层有44个探测器,28层总共有1232个探测器。

[0130] 仿真实验方案:利用堆芯三维节块方法堆芯计算软件Corca-3D,在所有堆芯节块截面、边界条件完整的情况下计算出某个 t_0 时刻堆芯探测器处快群、热群通量密度值,作为中子探测器实测快群、热群通量密度仿真值,Corca-3D采用的节块法两群扩散方程形式为(12) - (13)所示。

$$[0131] \quad -D_1 \nabla^2 \phi_1(r) + \Sigma_r \phi_1(r) = \frac{1}{k_{eff}} [\nu \Sigma_{f1} \phi_1(r) + \nu \Sigma_{f2} \phi_2(r)] \quad (12)$$

$$[0132] \quad -D_2 \nabla^2 \phi_2(r) + \Sigma_{a2} \phi_2(r) = \Sigma_{1 \rightarrow 2} \phi_1(r) \quad (13)$$

[0133] 将探测器仿真值随机取大约80%共计985个点作为训练数据集,代入式(6)中,形成数据驱动损失函数,取 $P_{data}=15$;剩余20%探测器247个仿真值作为测试集,验证网络模型输出准确性,训练集与测试集随机选取,分布如图7所示。控制方程损失函数(4)式中取 t_0 时刻Corca-3D采用的(12) - (13)扩散方程中的各截面参数,取 $P_f=1$;不考虑边界条件,即令(7)中 $P_b=0$ 。

[0134] 使用两个神经网络网络函数分别表示快群、热群通量密度,网络结构均为 $n=30,1=8$,两个网络交替迭代训练进行求解,训练迭代4000次停止,仿真实验结果如表6所示。

[0135] 表6堆芯实例重构测试集验证结果

[0136]	MSE_1	MSE_2	SE_{imax1}	SE_{imax2}	F_{Loss_all1}	F_{Loss_all2}
	1.6130e-04	9.2379e-05	0.0029	0.0008	9.2100e-03	8.3500e-03

[0137] 其中 MSE_1 、 MSE_2 分别为学习好的快群、热群神经网络输出与测试集相应点均方差; SE_{imax1} 、 SE_{imax2} 分别为测试集中快群与热群方差最大值。 F_{Loss_all1} 、 F_{Loss_all2} 分别为迭代训练结束时,热群、快群神经网络的加权损失函数,学习好的神经网络表示的通量密度分布如图8所示。

[0138] 由上可知,在没有边界条件情况下,只结合少量数据以及控制方程,即可实现深度学习逆向驱动求解中子双群扩散方程,测试集快群、热群通量密度验证计算均方误差最大为1.6130e-04,相对误差在1%左右,计算结果具有良好的精度。需要说明的是,本文采用的神经网络为基本的全连接神经网络架构,以及基本的深度学习优化方法,若采用更为先进的网络结构及深度学习方法,有理由相信可以进一步提高计算精度与效率。

[0139] 上面结合附图和实施例对本发明作了详细说明,但是本发明并不限于上述实施例,在本领域普通技术人员所具备的知识范围内,还可以在不脱离本发明宗旨的前提下作出各种变化。本发明中未作详细描述的内容均可以采用现有技术。




图1




图2




图3




图4





图5



28	堆芯顶部
27	
26	
25	
24	
23	
22	
21	
20	
19	
18	
17	
16	
15	
14	
13	
12	
11	
10	
9	
8	
7	
6	
5	
4	
3	
2	
1	堆芯底部

a

b

图6




图7




图8