



(21) 申请号 202410350721.9

(22) 申请日 2024.03.26

(65) 同一申请的已公布的文献号

申请公布号 CN 118378560 A

(43) 申请公布日 2024.07.23

(73) 专利权人 四川大学

地址 610000 四川省成都市一环路南一段
24号

专利权人 中国核动力研究设计院

(72) 发明人 彭德中 于洋 刘东 蒲睿韬

庞志鑫 秦阳 孙元

(74) 专利代理机构 北京卓岚智财知识产权代理
有限公司 11624

专利代理师 曾勇

(51) Int.Cl.

G06F 30/28 (2020.01)

G06F 30/27 (2020.01)

G06F 18/213 (2023.01)

G06N 3/0475 (2023.01)

G06N 3/094 (2023.01)

G06F 113/08 (2020.01)

G06F 119/14 (2020.01)

(56) 对比文件

CN 110348059 A, 2019.10.18

CN 115438575 A, 2022.12.06

审查员 俞姝颖


权利要求书3页 说明书6页 附图1页

(54) 发明名称

一种基于多视图生成式判别学习的流场预测方法

(57) 摘要

本发明公开了一种基于多视图生成式判别学习的流场预测方法,包括以下步骤:获取流场数据集;将数据集向量使用Mask算法得到不同视图的向量;输入流场向量形式特征数据,再使用主成分分析算法得到降维后的特征向量;将上述向量的耦合结果输入到生成器进行结果生成,得到一流场结构图的特征向量;将上述向量的耦合结果进行CFD软件模拟,得到另一流场结构图,并使用图像特征提取器得到其特征向量;将上述流场结构图的特征向量输入到鉴别器,计算损失值,通过损失值优化生成器和鉴别器;重复上述四个步骤,迭代优化模型,直到收敛;输入测试数据,利用优化模型得到输出作为流场预测结果。



1.一种基于多视图生成式判别学习的流场预测方法,其特征在于:包括以下步骤:

S1、获取流场数据集;

S2、将数据集向量使用Mask算法得到不同视图的向量;

S3、输入流场向量形式特征数据,再使用次成分分析算法得到降维后的特征向量;

S4、步骤S2和S3得到的向量进行耦合,将耦合结果输入到生成器进行结果生成,得到一流场结构图的特征向量;

S5、将耦合结果进行CFD软件模拟,得到另一流场结构图,并使用图像特征提取器得到其特征向量;

S6、将步骤S4和S5得到的流场结构图的特征向量输入到鉴别器,计算损失值,通过损失值优化生成器和鉴别器;

S7、重复步骤S3-S6,迭代优化模型,直到收敛;

S8、输入测试数据,利用优化的模型执行步骤S3-S4得到输出作为流场预测结果。

2.根据权利要求1所述的一种基于多视图生成式判别学习的流场预测方法,其特征在于:

所述步骤S1中流场数据集为已参数化的数据,其中参数为翼型的厚度分布参数、前缘形状参数、弯度分布参数、尾缘形状参数、升力线弯度参数、攻角、表面粗糙度和雷诺数;将上述参数表示为14维向量 Y_1 ,其表达式如下:

$$Y_1 \in \mathbb{R}^{14 \times n}$$

其中,n表示样本数量。

3.根据权利要求2所述的一种基于多视图生成式判别学习的流场预测方法,其特征在于:

所述步骤S2的具体方法如下:

随机生成两个向量 M_1 和 M_2 ,其表达式如下:

$$M_1 \in \mathbb{R}^{14 \times n}, M_2 \in \mathbb{R}^{14 \times n}$$

M_1 和 M_2 中的元素值均为0或者1;用 M_1 和 M_2 对向量 Y_1 进行Mask算法得到多视图向量 Y_2 和 Y_3 ,其表达式如下:

$$Y_2 \in \mathbb{R}^{14 \times n}, Y_3 \in \mathbb{R}^{14 \times n}。$$

4.根据权利要求3所述的一种基于多视图生成式判别学习的流场预测方法,其特征在于:

所述步骤S3中输入流场的特征数据F,使用次成分分析算法对F进行降维得到 Y_4 ,上述向量表达式如下:

$$F \in \mathbb{R}^{m \times n}, Y_4 \in \mathbb{R}^{1 \times n}$$

其中,m表示选择输入特征的个数;

所述次成分分析算法的具体步骤如下:

1)去中心化:将特征数据F中每一行元素减去该行所有元素的平均值,则特征数据F中

每个元素 f_{ij} 的计算公式如下:

$$f_{ij}^* = f_{ij} - \frac{1}{n} \sum_{k=1}^n f_{ik}$$

其中, f_{ij} 表示特征数据去中心化前的元素, f_{ij}^* 表示去中心化后的元素;

2) 计算协方差矩阵 FF^T

3) 求出协方差矩阵的特征值和特征向量,并将特征值从小到大排序,找出最小的特征值对应的特征向量 $P \in \mathbb{R}^{m \times 1}$;

4) 降维后得到向量 $Y_4 = P^T F$ 。

5. 根据权利要求4所述的一种基于多视图生成式判别学习的流场预测方法,其特征在于:

所述步骤S4是将向量 Y_4 作为行向量添加到 Y_1, Y_2 和 Y_3 中,耦合形成 Y_{14}, Y_{24} 和 Y_{34} ,其具体表达式如下:

$$Y_{14} \in \mathbb{R}^{15 \times n}, Y_{24} \in \mathbb{R}^{15 \times n}, Y_{34} \in \mathbb{R}^{15 \times n}$$

将耦合形成的向量分别输入到生成器G中,进而获得一流场结构图的特征向量如下:

$$G(Y_{14}), G(Y_{24}), G(Y_{34})$$

其中,生成器G包含7个反卷积层,每个反卷积层内核大小为 3×3 ,内核数量设置为512,生成器G实现了从翼型到相应流场图像的变换。

6. 根据权利要求5所述的一种基于多视图生成式判别学习的流场预测方法,其特征在于:

所述步骤S5的具体方法如下:

对步骤S4中耦合结果进行CFD模拟,获得另一流场结构图,再使用图片特征提取器对另一流场结构图进行提取,得到特征向量如下:

$$X_{14}, X_{24}, X_{34}。$$

7. 根据权利要求1所述的一种基于多视图生成式判别学习的流场预测方法,其特征在于:

所述步骤S6具体方法如下:

模型的目标函数表达式如下:

$$\min_{\theta^G} \max_{\theta^D} = E_{X \sim P_{data}} [\log(D(X))] + E_Y [\log(1 - D(G(Y)))]$$

其中, P_{data} 表示X的潜在分布,X表示CFD模拟的流场结构图的特征向量, θ^G, θ^D 分别表示生成器G和鉴别器D中可学习的参数,Y表示输入向量, $D(X)$ 表示向鉴别器D输入X后得到的输出, $G(Y)$ 表示向生成器G输入Y后得到的输出;

生成器G和鉴别器D的损失函数表达式分别如下:

$$Loss_G = E_Y[-\log(D(G(Y)|Y))] + \frac{\lambda}{MN} E_{(X,Y) \sim P_r(X,Y)} \|G(Y) - X\|_1$$

$$Loss_D = -E_{(X,Y) \sim P_r(X,Y)} [\log(D(X|Y))] - E_Y [\log(1 - D(G(Y)|Y))]$$

其中,M和N分别表示图像的长度和高度, λ 表示超参数, $P_r(X,Y)$ 表示X,Y的联合分布, $G(Y)|Y$ 表示将G(Y)和Y合并输入, $X|Y$ 表示将X和Y合并输入;

通过上述模型的损失函数计算损失值,并使用Adam优化器进行优化生成器和鉴别器,具体表达式如下:

$$\hat{\theta}^G = AdamOptimizer(Loss_G, \theta^G)$$

$$\hat{\theta}^D = AdamOptimizer(Loss_D, \theta^D)$$

其中, $\hat{\theta}^G$ 表示生成器优化后参数, $\hat{\theta}^D$ 表示鉴别器优化后参数,AdamOptimizer表示反向梯度优化器。

8.根据权利要求1所述的一种基于多视图生成式判别学习的流场预测方法,其特征在于:

所述步骤S8的具体方法如下:

输入测试数据 $Y_{test} \in \mathbb{R}^{14 \times 1}$ 和流场特征数据 $F_{test} \in \mathbb{R}^{m \times 1}$,使用次成分分析算法将 F_{test} 降维得到 $Y^* \in \mathbb{R}^{1 \times 1}$,将 Y^* 作为行向量添加到 Y_{test} 中耦合形成 $Y^1 \in \mathbb{R}^{15 \times 1}$,将耦合形成的 Y^1 输入到生成器G中,得到流场预测结果 $G(Y^1)$ 。

一种基于多视图生成式判别学习的流场预测方法

技术领域

[0001] 本发明属于人工智能与计算流体力学相结合的流场预测技术领域,更具体地说,涉及一种基于多视图生成式判别学习的流场预测方法。

背景技术

[0002] 准确地模拟和预测水流、空气流动、海洋流动等流场有助于研究和保护生态系统,预测洪水、风暴潮自然灾害。通过模拟和预测流场,可以优化建筑物、车辆、航空器等的设计,改进燃烧过程、冷却系统、空气动力学性能等。流场预测可用于评估工程结构的安全性,包括气流在建筑物周围的压力分布、风荷载对结构的影响等;同时对于流体中的湍流现象、涡旋结构、传热过程等也非常重要。在航空航天领域中,流场预测用于优化飞行器的设计和性能,考虑空气动力学效应、风阻和气动稳定性等。因此,高效、准确地获取气动性能对人类研究许多领域具有重要意义。

[0003] 气动性能通过风洞实验或计算流体力学(CFD)方法来获得,但风洞实验的结果依赖于设计师的先验知识,只有部分空气动力特性被考虑在实验中,而计算流体力学(CFD)耗时长,成本高。目前大多数机器学习的模型都是“浅”模型,只能在原函数空间中拟合很小的子集,且对整个复函数空间的拟合有限,对于远离训练数据的数据,“浅”模型缺乏泛化,在训练过程中通常需要大量数据来增强复杂问题的模型泛化能力。近年来,以深度方式训练出的模型在流场的精确预测方面表现良好,但该方式取决于从大规模数据中学习高容量模型的能力。由于CFD模拟的高成本支出,通常不可能获得足够的训练样本,不能覆盖所有条件的流场预测,不足的训练样本可能会降低预测的泛化性。生成对抗网络(GANs)被用来增加测试样本,以便模型能够推广到未见过条件的流场预测。

[0004] 一般的生成对抗网络(GANs)预测的流场是生成的低分辨率轮廓图像来表示的,而不是带有物理变量的像素图像。该图像几乎不能描述边界层或激波等剧烈变化的区域,因此该流场与真实数据数据略有不同,不能提供超临界、跨声速流场的准确预测,且现有方法大多数的模型训练都是单视图学习,泛化性不够。总的来说,现有的流场预测方法都有一些共同的局限性:只能预测低维气动性能,不能提供超临界、跨声速流场的准确预测,训练样本不足,且是单一视图学习,泛化性低。

发明内容

[0005] 本发明要解决的技术问题在于提供一种基于多视图生成式判别学习的流场预测方法,解决了现有的流场预测方法只能计算低维气动性能,不能提供高维气动性能下和边界层或激波等剧烈变化区域的流场预测和训练样本不足及单一视图学习导致训练模型泛化性低的问题。

[0006] 为了解决上述技术问题,本发明通过以下方式来实现:

[0007] 一种基于多视图生成式判别学习的流场预测方法,包括以下步骤:

[0008] S1、获取流场数据集;

- [0009] S2、将数据集向量使用Mask算法得到不同视图的向量；
- [0010] S3、输入流场向量形式特征数据,再使用次成分分析算法得到降维后的特征向量；
- [0011] S4、将上述向量的耦合结果输入到生成器进行结果生成,得到一流场结构图的特征向量；
- [0012] S5、将上述向量的耦合结果进行CFD软件模拟,得到另一流场结构图,并使用图像特征提取器得到其特征向量；
- [0013] S6、将上述流场结构图的特征向量输入到鉴别器,计算损失值,通过损失值优化生成器和鉴别器；
- [0014] S7、重复步骤S3-S6,迭代优化模型,直到收敛；
- [0015] S8、输入测试数据,利用优化的模型执行步骤S3-S4得到输出作为流场预测结果。
- [0016] 进一步地,所述步骤S1中流场数据集为已参数化的数据,其中参数为翼型的厚度分布参数、前缘形状参数、弯度分布参数、尾缘形状参数、升力线弯度参数、攻角、表面粗糙度和雷诺数;将上述参数表示为14维向量 Y_1 ,其表达式如下:

$$[0017] \quad Y_1 \in \mathbb{R}^{14 \times n}$$

[0018] 其中,n表示样本数量。

[0019] 进一步地,所述步骤S2的具体方法如下:

[0020] 随机生成两个向量 M_1 和 M_2 ,其表达式如下:

$$[0021] \quad M_1 \in \mathbb{R}^{14 \times n}, M_2 \in \mathbb{R}^{14 \times n}$$

[0022] M_1 和 M_2 中的元素值均为0或者1;用 M_1 和 M_2 对向量 Y_1 进行Mask算法得到多视图向量 Y_2 和 Y_3 ,其表达式如下:

$$[0023] \quad Y_2 \in \mathbb{R}^{14 \times n}, Y_3 \in \mathbb{R}^{14 \times n}$$

[0024] 进一步地,所述步骤S3中输入流场的特征数据F,使用次成分分析算法对F进行降维得到 Y_4 ,上述向量表达式如下:

$$[0025] \quad F \in \mathbb{R}^{m \times n}, Y_4 \in \mathbb{R}^{1 \times n}$$

[0026] 其中,m表示选择输入特征的个数;

[0027] 所述次成分分析算法的具体步骤如下:

[0028] 1) 去中心化将特征数据F中每一行元素减去该行所有元素的平均值,则特征数据F中每个元素 f_{ij} 的计算公式如下:

$$[0029] \quad f_{ij}^* = f_{ij} - \frac{1}{n} \sum_{k=1}^n f_{ik}$$

[0030] 其中, f_{ij} 表示特征数据去中心化前的元素, f_{ij}^* 表示去中心化后的元素;

[0031] 2) 计算协方差矩阵 FF^T

[0032] 3) 求出协方差矩阵的特征值和特征向量,并将特征值从小到大排序,找出最小的特征值对应的特征向量 $P \in \mathbb{R}^{m \times 1}$;

[0033] 4)降维后得到向量 $Y_4 = P^T F$ 。

[0034] 进一步地,所述步骤S4是将向量 Y_4 作为行向量添加到 Y_1, Y_2 和 Y_3 中,耦合形成 Y_{14}, Y_{24} 和 Y_{34} ,其具体表达式如下:

$$[0035] \quad Y_{14} \in \mathbb{R}^{15 \times n}, Y_{24} \in \mathbb{R}^{15 \times n}, Y_{34} \in \mathbb{R}^{15 \times n}$$

[0036] 将耦合形成的向量分别输入到生成器G中,进而获得一流场结构图(三个图片形式)的特征向量如下:

$$[0037] \quad G(Y_{14}), G(Y_{24}), G(Y_{34})$$

[0038] 其中,生成器G包含7个反卷积层,每个反卷积层内核大小为 3×3 ,内核数量设置为512,生成器G实现了从翼型到相应流场图像的变换。

[0039] 进一步地,所述步骤S5的具体方法如下:

[0040] 对步骤S4中耦合结果进行CFD模拟,获得到另一流场结构图,再使用图片特征提取器对另一流场结构图进行提取,得到特征向量如下:

$$[0041] \quad X_{14}, X_{24}, X_{34}$$

[0042] 进一步地,所述步骤S6具体方法如下:

[0043] 模型的目标函数表达式如下:

$$[0044] \quad \min_{\theta^G} \max_{\theta^D} = \mathbb{E}_{X \sim P_{data}} [\log(D(X))] + \mathbb{E}_Y [\log(1 - D(G(Y)))]$$

[0045] 其中, P_{data} 表示真实数据X的潜在分布, θ 表示网络的参数,Y表示输入向量,D(X)表示X输入得到的输出,G(Y)为Y输入得到的输出;

[0046] 生成器G和鉴别器D的损失函数表达式分别如下:

$$[0047] \quad Loss_G = \mathbb{E}_Y [-\log(D(G(Y)|Y))] + \frac{\lambda}{MN} \mathbb{E}_{(X,Y) \sim P_r(X,Y)} \|G(Y) - X\|_1$$

$$[0048] \quad Loss_D = -\mathbb{E}_{(X,Y) \sim P_r(X,Y)} [\log(D(X|Y))] - \mathbb{E}_Y [\log(1 - D(G(Y)|Y))]$$

[0049] 其中,X表示CFD模拟的流场结构图的特征向量,M和N分别表示图像的长度和高度,生成器损失函数的第一项表示生成图像和真实图像分布之间的交叉熵,第二项表示整个图像上的平均绝对值误差, λ 表示超参数, $P_r(X,Y)$ 表示X,Y的联合分布, $G(Y)|Y$ 表示将G(Y)和Y合并输入, $X|Y$ 表示将X和Y合并输入;

[0050] 通过上述模型的目标函数计算损失值,并使用Adam优化器进行优化生成器和鉴别器,具体表达式如下:

$$[0051] \quad \hat{\theta}^G = AdamOptimizer(Loss_G, \theta^G)$$

$$[0052] \quad \hat{\theta}^D = AdamOptimizer(Loss_D, \theta^D)$$

[0053] 其中, $\hat{\theta}^G$ 表示生成器优化后参数, $\hat{\theta}^D$ 表示鉴别器优化后参数,AdamOptimizer表示反向梯度优化器。

[0054] 进一步地,所述步骤S8的具体方法如下:

[0055] 输入测试数据 $Y_{test} \in \mathbb{R}^{14 \times 1}$ 和流场特征数据 $F_{test} \in \mathbb{R}^{m \times 1}$, 使用次成分分析算法将 F_{test} 降维得到 $Y^* \in \mathbb{R}^{1 \times 1}$, 将 Y^* 作为行向量添加到 Y_{test} 中耦合形成 $Y^1 \in \mathbb{R}^{15 \times 1}$, 将耦合形成的 Y^1 输入到生成器 G 中, 得到输出 $G(Y^1)$, $G(Y^1)$ 即流场预测结果。

[0056] 与现有技术相比, 本发明具有的有益效果:

[0057] 本发明生成对抗网络增加测试数据, 以便模型能推广到未见过条件的流场预测; 通过融合不同视图的特征, 提供全面的信息, 提高模型的表达能力和泛化能力, 同时利用多个视图降低单个视图数据源的偏差影响, 减少过拟合, 提供更准确的预测能力。本申请额外输入测试数据的流场代表性特征提高模型在超临界、跨声速流场的预测准确度, 采用次成分分析算法 (MCA) 压缩数据维度, 能够提高计算效率, 保证模型学习的是测试数据的特征。

附图说明

[0058] 图1为本发明流场预测方法的流程示意图。

具体实施方式

[0059] 下面结合附图和具体实施例对本发明的具体实施方式作进一步详细的说明。

[0060] 如图1所示, 一种基于多视图生成式判别学习的流场预测方法, 包括以下步骤:

[0061] S1、获取流场数据集;

[0062] S2、将数据集向量使用Mask算法得到不同视图的向量;

[0063] S3、输入流场向量形式特征数据, 再使用次成分分析算法得到降维后的特征向量;

[0064] S4、将上述向量的耦合结果输入到生成器进行结果生成, 得到一流场结构图的特征向量;

[0065] S5、将上述向量的耦合结果进行CFD软件模拟, 得到另一流场结构图, 并使用图像特征提取器得到其特征向量;

[0066] S6、将上述流场结构图的特征向量输入到鉴别器, 计算损失值, 通过损失值优化生成器和鉴别器;

[0067] S7、重复步骤S3-S6, 迭代优化模型, 直到收敛;

[0068] S8、输入测试数据, 利用优化的模型执行步骤S3-S4得到输出作为流场预测结果。

[0069] 进一步地, 所述步骤S1中流场数据集为已参数化的数据, 其中参数为翼型的厚度分布参数、前缘形状参数、弯度分布参数、尾缘形状参数、升力线弯度参数、攻角、表面粗糙度和雷诺数;

[0070] 翼型厚度分布描述翼型沿弦长方向的厚度变化情况, 翼型前缘形状描述翼型前缘的几何形状, 翼型弯度分布描述翼型在升力线上的弯曲情况, 翼型尾缘形状描述翼型尾缘的几何形状, 升力线形状描述翼型升力线的几何形状, 攻角是翼型相对于来流方向的角度, 翼型表面粗糙度描述翼型表明的光滑程度, 雷诺数在翼型气动性能计算中表示流体的惯性力和粘性力的相对重要性。

[0071] 将上述参数表示为14维向量 Y_1 , 其表达式如下:

[0072] $Y_1 \in \mathbb{R}^{14 \times n}$

[0073] 其中, n 表示样本数量。

[0074] 进一步地, 所述步骤S2的具体方法如下:

[0075] 因实际样本的缺少, 采用mask算法生成向量模拟多视图, 具体步骤是: 随机生成两个向量 M_1 和 M_2 , 其表达式如下:

$$[0076] \quad M_1 \in \mathbb{R}^{14 \times n}, \quad M_2 \in \mathbb{R}^{14 \times n}$$

[0077] M_1 和 M_2 中的元素值均为0或者1; 用 M_1 和 M_2 对向量 Y_1 进行Mask算法得到多视图向量 Y_2 和 Y_3 , 其表达式如下:

$$[0078] \quad Y_2 \in \mathbb{R}^{14 \times n}, \quad Y_3 \in \mathbb{R}^{14 \times n}$$

[0079] 进一步地, 所述步骤S3中输入流场的特征数据 F , 使用次成分分析算法 (MCA) 对 F 进行降维得到 Y_4 , 上述向量表达式如下:

$$[0080] \quad F \in \mathbb{R}^{m \times n}, \quad Y_4 \in \mathbb{R}^{1 \times n}$$

[0081] 其中, m 表示选择输入特征的个数;

[0082] 所述次成分分析算法的具体步骤如下:

[0083] 1) 去中心化将特征数据 F 中每一行元素减去该行所有元素的平均值, 则特征数据 F 中每个元素 f_{ij} 的计算公式如下:

$$[0084] \quad f_{ij}^* = f_{ij} - \frac{1}{n} \sum_{k=1}^n f_{ik}$$

[0085] 其中, f_{ij} 表示特征数据去中心化前的元素, f_{ij}^* 表示去中心化后的元素;

[0086] 2) 计算协方差矩阵 FF^T

[0087] 3) 求出协方差矩阵的特征值和特征向量, 并将特征值从小到大排序, 找出最小的特征值对应的特征向量 $P \in \mathbb{R}^{m \times 1}$;

[0088] 4) 降维后得到向量 $Y_4 = P^T F$ 。

[0089] 进一步地, 所述步骤S4是将向量 Y_4 作为行向量添加到 Y_1, Y_2 和 Y_3 中, 耦合形成 Y_{14}, Y_{24} 和 Y_{34} , 其具体表达式如下:

$$[0090] \quad Y_{14} \in \mathbb{R}^{15 \times n}, \quad Y_{24} \in \mathbb{R}^{15 \times n}, \quad Y_{34} \in \mathbb{R}^{15 \times n}$$

[0091] 将耦合形成的向量分别输入到生成器 G 中, 进而获得一流场结构图 (三个图片形式) 的特征向量如下:

$$[0092] \quad G(Y_{14}), G(Y_{24}), G(Y_{34})$$

[0093] 其中, 生成器 G 包含7个反卷积层, 没有池化层和全连接层, 每个反卷积层内核大小为 3×3 , 内核数量设置为512, 生成器 G 实现了从翼型到相应流场图像的变换。

[0094] 进一步地, 所述步骤S5的具体方法如下:

[0095] 对步骤S4中耦合结果进行CFD模拟, 获得到另一流场结构图 (三个流场结构模拟图), 再使用图片特征提取器对另一流场结构图进行提取, 特征提取器可采用预训练的 RestNet, VGG模型等, 得到特征向量如下:

[0096] X_{14}, X_{24}, X_{34}

[0097] 进一步地,所述步骤S6具体方法如下:

[0098] 模型的目标函数表达式如下:

$$[0099] \quad \min_{\theta^G} \max_{\theta^D} = \mathbb{E}_{X \sim P_{data}} [\log(D(X))] + \mathbb{E}_Y [\log(1 - D(G(Y)))]$$

[0100] 其中, P_{data} 表示真实数据X的潜在分布, θ 表示网络的参数, Y表示输入向量, D表示鉴别器, $D(X)$ 表示X作为输入得到的输出, G为生成器, $G(Y)$ 为Y作为输入得到的输出;

[0101] 生成器G和鉴别器D的损失函数表达式分别如下:

$$[0102] \quad Loss_G = \mathbb{E}_Y [-\log(D(G(Y)|Y))] + \frac{\lambda}{MN} \mathbb{E}_{(X,Y) \sim P_r(X,Y)} \|G(Y) - X\|_1$$

$$[0103] \quad Loss_D = -\mathbb{E}_{(X,Y) \sim P_r(X,Y)} [\log(D(X|Y))] - \mathbb{E}_Y [\log(1 - D(G(Y)|Y))]$$

[0104] 其中, X表示CFD模拟的流场结构图的特征向量, M和N分别表示图像的长度和高度, 生成器损失函数的第一项表示生成图像和真实图像分布之间的交叉熵, 第二项表示整个图像上的平均绝对值误差, λ 平衡交叉熵和整个图像上的平均绝对值误差的表示超参数, $P_r(X, Y)$ 表示X, Y的联合分布, $G(Y)|Y$ 表示将G(Y)和Y合并输入, $X|Y$ 表示将X和Y合并输入;

[0105] 通过上述模型的损失函数计算损失值, 并使用Adam优化器进行优化生成器和鉴别器, 具体表达式如下:

$$[0106] \quad \hat{\theta}^G = AdamOptimizer(Loss_G, \theta^G)$$

$$[0107] \quad \hat{\theta}^D = AdamOptimizer(Loss_D, \theta^D)$$

[0108] 其中, $\hat{\theta}^G$ 表示生成器优化后参数, $\hat{\theta}^D$ 表示鉴别器优化后参数, AdamOptimizer表示反向梯度优化器。

[0109] 进一步地,所述步骤S8的具体方法如下:

[0110] 输入测试数据 $Y_{test} \in \mathbb{R}^{14 \times 1}$ 和流场特征数据 $F_{test} \in \mathbb{R}^{m \times 1}$, 使用主成分分析算法将 F_{test} 降维得到 $Y^* \in \mathbb{R}^{1 \times 1}$, 将 Y^* 作为行向量添加到 Y_{test} 中耦合形成 $Y^1 \in \mathbb{R}^{15 \times 1}$, 将耦合形成的 Y^1 输入到生成器G中, 得到输出 $G(Y^1)$, $G(Y^1)$ 即流场预测结果。

[0111] 以上所述仅是本发明的实施方式, 再次声明, 对于本技术领域的普通技术人员来说, 在不脱离本发明原理的前提下, 还可以对本发明进行若干改进, 这些改进也列入本发明权利要求的保护范围内。




图1