



(12) 发明专利申请

(10) 申请公布号 CN 120470928 A

(43) 申请公布日 2025. 08. 12

(21) 申请号 202510664146.4

(22) 申请日 2025.05.22

(71) 申请人 哈尔滨工程大学

地址 150001 黑龙江省哈尔滨市南岗区燎
原街道南通大街145号

申请人 中国核动力研究设计院

(72) 发明人 钱浩 陈广亮 刘东 于洋

(74) 专利代理机构 北京知汇宏图知识产权代理
有限公司 11520

专利代理师 张劲锋

(51) Int. Cl.

G06F 30/27 (2020.01)

G06F 30/28 (2020.01)

G06F 17/11 (2006.01)

G06N 3/0499 (2023.01)

G06N 3/084 (2023.01)

G06F 18/10 (2023.01)

G06F 18/213 (2023.01)

G06F 113/08 (2020.01)

G06F 119/14 (2020.01)

G06F 111/04 (2020.01)

G06F 111/10 (2020.01)


权利要求书3页 说明书11页 附图3页

(54) 发明名称

基于数据与模型自适应修正的智能数值计算方法及系统

(57) 摘要

本发明公开一种基于数据与模型自适应修正的智能数值计算方法及系统,该方法包括:明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理;根据所需计算的系统,确定系统的控制方程、边界条件与初始条件;基于数据特征和方程特征,选择数据自适应修正技术、模型自适应调节技术;设计用于求解的神经网络架构;定义相应形式的调节变量;设计模型的损失函数;训练并优化模型,以确保模型精度达到最高;输出模型参数,完成对提出的物理问题的求解。本发明在求解过程中滤除数据噪声,并自动发现和修正仿真模型中的不完备参数,通过动态调整数据或模型,优化数据与模型之间的匹配,从而提高数据处理和模型预测的准确性。



1. 一种基于数据与模型自适应修正的智能数值计算方法,其特征在于,包括以下步骤:

(1) 明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理;

(2) 根据所需计算的系统,确定系统的控制方程、边界条件与初始条件;

(3) 基于步骤(1)中的数据特征和步骤(2)中的方程特征,选择修正技术,具体包括:当数据中存在显著噪声且方程和边界条件相对完备时,采用数据自适应修正技术,数据自适应修正技术通过引入可训练变量来中和数据中的噪声;当数据准确,但方程存在缺失值或简化误差时,采用模型自适应调节技术,模型自适应调节技术通过引入可训练变量来弥补方程中的残缺值或修正被忽视的物理效应;

(4) 设计用于求解的神经网络架构,明确神经网络架构的输入、输出以及网络结构;

(5) 根据所选择的修正技术和问题特征,定义相应形式的调节变量;

(6) 基于所选择的修正技术,设计模型的损失函数;

(7) 基于收集的数据、边界条件以及经修正技术修正的物理方程对神经网络架构进行训练,直到模型收敛,并根据训练结果调整神经网络架构和优化函数,得到最佳性能的模型;

(8) 基于最佳性能的模型,输出模型参数,完成对步骤(1)中提出的物理问题的求解。

2. 根据权利要求1所述的基于数据与模型自适应修正的智能数值计算方法,其特征在于,所述步骤(1),明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理,具体包括:

明确所需解决的物理问题的性质和范围;

收集与物理问题相关的数据,进行初步分析以识别数据特征,并判断数据中是否存在噪声,如果发现噪声,则根据实际情况和可行性,对噪声模型进行假设;

其中,对噪声模型进行假设,包括:基于数据分析的结果,建立噪声模型,假设噪声类型,并估计噪声的阈值及其分布特性。

3. 根据权利要求1所述的基于数据与模型自适应修正的智能数值计算方法,其特征在于,所述步骤(2),根据所需计算的系统,确定系统的控制方程、边界条件与初始条件,具体包括:

确定描述系统行为的控制方程,评估方程中是否存在残缺值或简化假设,并考虑这些因素对系统精度的影响;

根据现有数据和实际情况,设定系统的初始条件和边界条件,以确保模型的准确性和适用性。

4. 根据权利要求1所述的基于数据与模型自适应修正的智能数值计算方法,其特征在于,所述步骤(4),设计用于求解的神经网络架构,明确神经网络架构的输入、输出以及网络结构,具体包括:

基于选择的修正技术,设计神经网络架构,并选择优化算法;

定义神经网络的输入和输出,确保网络能够处理和改进物理方程中的各个方面,网络输出直接或通过变换计算数据损失和控制方程的损失。

5. 根据权利要求1所述的基于数据与模型自适应修正的智能数值计算方法,其特征在于,所述步骤(5),根据所选择的修正技术和问题特征,定义相应形式的调节变量,具体包括:

若所选择的修正技术为数据自适应修正技术,在神经网络中引入与噪声数据尺寸一致的可训练变量,所述可训练变量作为模型参数或网络层的输出,用于表示数据中的噪声;并根据已有的噪声信息,设置可训练变量的分布,在求解中规定其阈值,以实现更加准确的修正,避免过度修正;

若所选择的修正技术为模型自适应调节技术,在神经网络中引入与模型简化相关的可训练变量,所述可训练变量为单一数值或数值分布,用于弥补方程中的残缺值或修正被忽视的物理效应。

6. 根据权利要求1所述的基于数据与模型自适应修正的智能数值计算方法,其特征在于,所述步骤(6),基于所选择的修正技术,设计模型的损失函数;

设计内部数据点损失函数:所述内部数据点损失函数用于衡量模型输出与实际数据之间的差异,针对数据自适应修正技术,通过将神经网络输出物理量与可训练的噪声变量相加,以可训练变量来中和数据的噪声,减小噪声对数据的影响,从而实现数据修正;

设计边界数据点损失函数,用于评估模型在边界条件下的表现;

设计方程损失函数,用于评估模型对控制方程的符合程度,对于方程中的缺失值,明确其所在位置,并在这些位置引入对应的可训练变量;对于由于模型简化或计算误差导致的数据和方程的总体差异,在方程末尾定义统一的调节参数,所述调节参数的尺寸应与总训练点的尺寸一致,用于中和方程误差,并通过数据逼近量化数据与方程之间的差异。

7. 根据权利要求1所述的基于数据与模型自适应修正的智能数值计算方法,其特征在于,所述步骤(8),基于最佳性能的模型,输出模型参数,完成对步骤(1)中提出的物理问题的求解,具体包括:

数据去噪:针对数据自适应修正技术,根据输出的用于中和数据噪声的变量确定噪声类型以及噪声分布,并可根据该变量与原始噪声数据的线性变换还原出高精度数据;

方程确定:针对方程自适应调节技术,根据神经网络迭代出的参数,确定物理方程中的缺失值或数据与方程之间的偏差值,并进行相应的修正。

8. 一种基于数据与模型自适应修正的智能数值计算系统,应用于权利要求1-7任一项所述的基于数据与模型自适应修正的智能数值计算方法,其特征在于,包括:

数据处理模块,用于明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理;

方程确定模块,用于根据所需计算的系统,确定系统的控制方程、边界条件与初始条件;

修正技术选择模块,用于基于数据特征和方程特征,选择合适的修正技术;

网络架构设计模块,用于设计用于求解的神经网络架构,明确神经网络架构的输入、输出以及网络结构;

调节变量定义模块,用于根据所选择的修正技术和问题特征,定义相应形式的调节变量;

损失函数设计模块,用于基于所选择的修正技术,设计模型的损失函数;

模型训练模块,用于基于收集的数据、边界条件以及经修正技术修正的物理方程对神经网络架构进行训练,直到模型收敛,并根据训练结果调整神经网络架构和优化函数,得到最佳性能模型;

问题求解模块,用于基于最佳性能的模型,输出模型参数,完成对步骤(1)中提出的物理问题的求解。

9.一种计算机可读存储介质,其上存储有计算机程序,其特征在于,所述计算机程序运行时执行权利要求1-7任一项所述的基于数据与模型自适应修正的智能数值计算方法。

10.一种计算机设备,包括存储器和处理器,所述存储器上存储有可在所述处理器上运行的计算机程序,其特征在于,所述处理器运行所述计算机程序时执行权利要求1-7任一项所述的基于数据与模型自适应修正的智能数值计算方法。

基于数据与模型自适应修正的智能数值计算方法及系统

技术领域

[0001] 本发明涉及智能数值计算技术领域,特别是涉及一种基于数据与模型自适应修正的智能数值计算方法及系统。

背景技术

[0002] 物理信息神经网络通过将物理方程的残差项与数据的损失项同时融入神经网络的损失函数,实现了物理方程与数据的有效融合。该方法通过物理方程与数据的双重驱动机制,易于实现物理问题的正问题和反问题的高效求解。在此过程中,数据来源通常包括实验数据、仿真结果和数值计算。实验数据通常表现出稀疏性和噪声的特征,这对模型的精确性提出了挑战。首先,由于测量设备的误差、环境干扰以及随机测量波动的影响,实验数据不可避免地会含有噪声,从而在建模和分析中引入额外的误差。其次,由于实验条件的复杂性以及测量设备的局限性,诸如流体速度或温度梯度等边界条件的精确测量极具挑战性,边界条件的测量误差导致了一些关键参数的不确定性。此外,受技术或成本限制,数据采集通常只能在有限的空间或时间点进行,导致实验数据的稀疏性增加了模型的不确定性,使得难以精确描述系统的整体行为状态。

[0003] 另一方面,仿真与数值计算通常基于简化的物理模型,并依赖一些难以精确确定的经验参数。这些参数在不同条件下可能会发生显著变化,导致仿真结果的误差加剧,进而降低模型的准确性和鲁棒性。例如,在求解复杂物理模型(如Navier-Stokes方程)时,直接求解会消耗大量计算资源。为提高计算效率,通常采用简化模型,如Reynolds-Averaged Navier-Stokes (RANS) 模型。这种简化在处理强湍流等非线性现象时,往往引入显著的模型误差。

[0004] 因此,当前研究的重点在于如何在含噪声数据中实现高精度求解,并有效去除数据中的噪声。此外,依据已有数据对方程进行自适应调节,使其能够在求解过程中动态修正参数,从而实现对物理过程的推导及高精度求解,亦是关键的研究方向。

发明内容

[0005] 本发明的目的是提供一种基于数据与模型自适应修正的智能数值计算方法及系统,在求解过程中滤除数据噪声,并自动发现和修正仿真模型中的不完备参数,通过动态调整数据或模型,优化数据与模型之间的匹配,从而提高数据处理和模型预测的准确性。

[0006] 为实现上述目的,本发明提供了如下方案:

[0007] 一种基于数据与模型自适应修正的智能数值计算方法,包括以下步骤:

[0008] (1) 明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理;

[0009] (2) 根据所需计算的系统,确定系统的控制方程、边界条件与初始条件;

[0010] (3) 基于步骤(1)中的数据特征和步骤(2)中的方程特征,选择修正技术,具体包括:当数据中存在显著噪声且方程和边界条件相对完备时,采用数据自适应修正技术,数据自适应修正技术通过引入可训练变量来中和数据中的噪声;当数据准确,但方程存在缺失

值或简化误差时,采用模型自适应调节技术,模型自适应调节技术通过引入可训练变量来弥补方程中的残缺值或修正被忽视的物理效应;

[0011] (4) 设计用于求解的神经网络架构,明确神经网络架构的输入、输出以及网络结构;

[0012] (5) 根据所选择的修正技术和问题特征,定义相应形式的调节变量;

[0013] (6) 基于所选择的修正技术,设计模型的损失函数;

[0014] (7) 基于收集的数据、边界条件以及经修正技术修正的物理方程对神经网络架构进行训练,直到模型收敛,并根据训练结果调整神经网络架构和优化函数,得到最佳性能模型;

[0015] (8) 基于最佳性能的模型,输出模型参数,完成对步骤(1)中提出的物理问题的求解。

[0016] 进一步地,所述步骤(1),明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理,具体包括:

[0017] 明确所需解决的物理问题的性质和范围;

[0018] 收集与物理问题相关的数据,进行初步分析以识别数据特征,并判断数据中是否存在噪声,如果发现噪声,则根据实际情况和可行性,对噪声模型进行假设;

[0019] 其中,对噪声模型进行假设,包括:基于数据分析的结果,建立噪声模型,假设噪声类型,并估计噪声的阈值及其分布特性。

[0020] 进一步地,所述步骤(2),根据所需计算的系统,确定系统的控制方程、边界条件与初始条件,具体包括:

[0021] 确定描述系统行为的控制方程,评估方程中是否存在残缺值或简化假设,并考虑这些因素对系统精度的影响;

[0022] 根据现有数据和实际情况,设定系统的初始条件和边界条件,以确保模型的准确性和适用性。

[0023] 进一步地,所述步骤(3),基于步骤(1)中的数据特征和步骤(2)中的方程特征,选择合适的修正技术,具体包括:

[0024] 当数据中存在显著噪声且方程和边界条件相对完备时,采用数据自适应修正技术,数据自适应修正技术通过引入可训练变量来中和数据中的噪声;

[0025] 当数据准确,但方程存在缺失值或简化误差时,采用模型自适应调节技术,模型自适应调节技术通过引入可训练变量来弥补方程中的残缺值或修正被忽视的物理效应。

[0026] 进一步地,所述步骤(4),设计用于求解的神经网络架构,明确神经网络架构的输入、输出以及网络结构,具体包括:

[0027] 基于选择的修正技术,设计神经网络架构,并选择优化算法;

[0028] 定义神经网络的输入和输出,确保网络能够处理和改进物理方程中的各个方面,网络输出直接或通过变换计算数据损失和控制方程的损失。

[0029] 进一步地,所述步骤(5),根据所选择的修正技术和问题特征,定义相应形式的调节变量,具体包括:

[0030] 若所选择的修正技术为数据自适应修正技术,在神经网络中引入与噪声数据尺寸一致的可训练变量,所述可训练变量作为模型参数或网络层的输出,用于表示数据中的噪

声;并根据已有的噪声信息,设置可训练变量的分布,在求解中规定其阈值,以实现更加准确的修正,避免过度修正;

[0031] 若所选择的修正技术为模型自适应调节技术,在神经网络中引入与模型简化相关的可训练变量,所述可训练变量为单一数值或数值分布,用于弥补方程中的残缺值或修正被忽视的物理效应。

[0032] 进一步地,所述步骤(6),基于所选择的修正技术,设计模型的损失函数;

[0033] 设计内部数据点损失函数:所述内部数据点损失函数用于衡量模型输出与实际数据之间的差异,针对数据自适应修正技术,通过将神经网络输出物理量与可训练的噪声变量相加,以可训练变量来中和数据的噪声,减小噪声对数据的影响,从而实现数据修正;

[0034] 设计边界数据点损失函数,用于评估模型在边界条件下的表现;

[0035] 设计方程损失函数,用于评估模型对控制方程的符合程度,对于方程中的缺失值,明确其所在位置,并在这些位置引入对应的可训练变量;对于由于模型简化或计算误差导致的数据和方程的总体差异,在方程末尾定义统一的调节参数,所述调节参数的尺寸应与总训练点的尺寸一致,用于中和方程误差,并通过数据逼近量化数据与方程之间的差异。

[0036] 进一步地,所述步骤(8),基于最佳性能的模型,输出模型参数,完成对步骤(1)中提出的物理问题的求解,具体包括:

[0037] 数据去噪:针对数据自适应修正技术,根据输出的用于中和数据噪声的变量确定噪声类型以及噪声分布,并可根据该变量与原始噪声数据的线性变换还原出高精度数据;

[0038] 方程确定:针对方程自适应调节技术,根据神经网络迭代出的参数,确定物理方程中的缺失值或数据与方程之间的偏差值,并进行相应的修正。

[0039] 本发明还提供一种基于数据与模型自适应修正的智能数值计算系统,应用于上述的基于数据与模型自适应修正的智能数值计算方法,包括:

[0040] 数据处理模块,用于明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理;

[0041] 方程确定模块,用于根据所需计算的系统,确定系统的控制方程、边界条件与初始条件;

[0042] 修正技术选择模块,用于基于数据特征和方程特征,选择合适的修正技术;

[0043] 网络架构设计模块,用于设计用于求解的神经网络架构,明确神经网络架构的输入、输出以及网络结构;

[0044] 调节变量定义模块,用于根据所选择的修正技术和问题特征,定义相应形式的调节变量;

[0045] 损失函数设计模块,用于基于所选择的修正技术,设计模型的损失函数;

[0046] 模型训练模块,用于基于收集的数据、边界条件以及经修正技术修正的物理方程对神经网络架构进行训练,直到模型收敛,并根据训练结果调整神经网络架构和优化函数,得到最佳性能的模型;

[0047] 问题求解模块,用于基于最佳性能的模型,输出模型参数,完成对步骤(1)中提出的物理问题的求解。

[0048] 此外,本发明还提供种计算机可读存储介质,其上存储有计算机程序,其特征在于,所述计算机程序运行时执行上述的基于数据与模型自适应修正的智能数值计算方法

[0049] 此外,本发明还提供一种计算机设备,包括存储器和处理器,所述存储器上存储有可在所述处理器上运行的计算机程序,其特征在于,所述处理器运行所述计算机程序时执行上述的基于数据与模型自适应修正的智能数值计算方法。

[0050] 根据本发明提供的具体实施例,本发明提供的基于数据与模型自适应修正的智能数值计算方法,公开了以下技术效果:

[0051] 1.提升模型准确性和可靠性:

[0052] 当采用数据与物理模型融合的方法求解物理问题时,数据与物理方程的匹配性对模型的预测精度至关重要。当数据与方程不匹配时,由于两者之间的相互制约,导致求解过程难以收敛,进而难以实现高精度的结果。针对这一问题,本发明提出了数据自适应修正技术和模型自适应调节技术,通过引入修正变量,减小数据与方程之间的差异对求解的负面影响。

[0053] 具体而言,当数据中存在显著噪声且物理方程和边界条件相对完备时,数据自适应修正技术通过引入可训练变量,来中和数据中的噪声。并在物理方程和边界条件的约束下,该技术能够实现高精度的求解和数据修正。而在数据较为准确但物理方程存在缺失或简化误差的情况下,模型自适应调节技术则通过引入可训练变量,弥补方程中的缺失或因简化被忽略的物理效应。该方法以数据为导向,对模型的控制方程进行修正。

[0054] 通过这两种技术,可以有效地避免数据噪声或方程残缺、简化所带来的影响,避免数据与方程之间的相互制约,从而实现高精度的求解。

[0055] 2.噪声确定与模型方程优化

[0056] 数据自适应修正技术在高噪声环境下能够实现高精度训练,有效滤除数据中的噪声。该技术通过引入数据修正变量,以物理模型的方程和边界条件为基础,减少数据中的噪声影响。修正后的模型输出能够准确确定噪声的分布特征,并通过该修正变量与原始噪声数据的线性变换,还原出更高精度的数据。

[0057] 当物理模型存在简化或不完备性时,模型自适应调节技术通过动态调整模型方程中的变量,以补偿模型的不足。该技术能够依据调节变量的输出值,对物理过程进行推导和物理方程的修正,从而为复杂物理现象的研究提供一种可靠的方法。

[0058] 可见,本发明开发了一种数据自适应修正技术和模型自适应调节技术,能够在求解过程中滤除数据噪声,并自动发现和修正仿真模型中的不完备参数。这将有助于提升数据与模型融合技术的应用场景,提高模型的准确性和鲁棒性,为复杂工程问题的解决提供更加可靠的工具。

附图说明

[0059] 为了更清楚地说明本发明实施例或现有技术中的技术方案,下面将对实施例中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图仅仅是本发明的一些实施例,对于本领域普通技术人员来讲,在不付出创造性劳动性的前提下,还可以根据这些附图获得其他的附图。

[0060] 图1为本发明实施例基于数据与模型自适应修正的智能数值计算方法流程示意图;

[0061] 图2为本发明实施例基于数字自适应修正技术的神经网络算法架构;

[0062] 图3为本发明实施例基于模型自适应调节技术的神经网络算法架构。

具体实施方式

[0063] 下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0064] 本发明的目的是基于物理信息神经网络的数据自适应修正技术和模型自适应调节技术,解决数据中的噪声问题以及模型中存在的参数不确定性问题。

[0065] 为使本发明的上述目的、特征和优点能够更加明显易懂,下面结合附图和具体实施方式对本发明作进一步详细的说明。

[0066] 如图1所示,本发明提供的基于数据与模型自适应修正的智能数值计算方法,包括以下步骤:

[0067] (1) 明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理,具体包括:

[0068] 步骤1a-1b,问题定义:明确所需解决的物理问题的性质和范围;

[0069] 步骤1c,收集数据与初步分析:收集与问题相关的数据,进行初步分析以识别数据特征,并判断数据中是否存在噪声,如果发现噪声,则根据实际情况和可行性,对噪声模型进行假设;

[0070] 其中,噪声模型假设:基于数据分析的结果,建立噪声模型,假设噪声类型(例如高斯噪声、椒盐噪声等),并估计噪声的阈值及其分布特性。

[0071] (2) 根据所需计算的系统,确定系统的控制方程、边界条件与初始条件,具体包括:

[0072] 控制方程:确定描述系统行为的控制方程,评估方程中是否存在残缺值或简化假设,并考虑这些因素对系统精度的影响;

[0073] 初始条件和边界条件:根据现有数据和实际情况,设定系统的初始条件和边界条件,以确保模型的准确性和适用性。

[0074] (3) 基于步骤(1)中的数据特征和步骤(2)中的方程特征,选择合适的修正技术,具体包括:

[0075] 步骤3a,数据自适应修正技术:当数据中存在显著噪声且方程和边界条件相对完备时,采用数据自适应修正技术。此技术通过引入可训练变量来中和数据中的噪声。如图2所示,为基于数字自适应修正技术的神经网络算法架构,数据自适应修正技术在神经网络中引入可迭代的修正项,以降低噪声对模型性能的影响。

[0076] 以二维NS方程为例:

[0077] a) Navier-Stokes方程

[0078] Navier-Stokes方程的基本形式为:

$$(\mathbf{u} \cdot \nabla) \mathbf{u} = -\nabla p + \nu \nabla^2 \mathbf{u}$$

[0079]

$$\nabla \cdot \mathbf{u} = 0$$

[0080] 其中,u表示速度矢量,p表示压力,\nu表示运动粘性系数。

[0081] b) 流函数的引入

[0082] 针对二维不可压缩流动问题,可以引入流函数 ψ ,使得速度矢量 $\mathbf{u}$ 可以表示为:

$$[0083] \quad \mathbf{u} = \left(\frac{\partial \psi}{\partial y}, -\frac{\partial \psi}{\partial x} \right)$$

[0084] 通过引入流函数,自动满足了连续性方程 $\nabla \cdot \mathbf{u} = 0$,因此只需要计算动量方程,简化了计算过程,降低问题的复杂性,便于求解。

[0085] c) 数据和方程的无量纲化

[0086] 由于反应堆堆芯的复杂运行条件,其流场压力、速度以及密度等变量数值差异较大,影响神经网络计算的收敛性,需对流场参数以及方程和数据进行无量纲化处理。定义无量纲变量:

$$[0087] \quad \mathbf{u}^* = \frac{\mathbf{u}}{U}, \quad p^* = \frac{p}{\rho U^2}, \quad \mathbf{x}^* = \frac{\mathbf{x}}{L}$$

[0088] 其中, U 是特征速度, L 是特征长度, $\mathbf{x}$ 代表位置矢量。经过无量纲化处理后,NS方程可以表示为:

$$[0089] \quad (\mathbf{u}^* \cdot \nabla^*) \mathbf{u}^* = -\nabla^* p^* + \frac{1}{Re} \nabla^{*2} \mathbf{u}^*$$

$$\nabla^* \cdot \mathbf{u}^* = 0$$

[0090] 其中, $Re = UL/\nu$ 是雷诺数,表示惯性力和粘性力的比值。无量纲化处理有助于避免数值差异过大,导致神经网络难以收敛。

[0091] d) 数据自适应修正技术:当数据中存在显著噪声且方程和边界条件相对完备时,采用数据自适应修正技术。此技术通过引入可训练变量来中和数据中的噪声。如图2所示,为基于数字自适应修正技术的神经网络算法架构,数据自适应修正技术在神经网络中引入可迭代的修正项,以降低噪声对模型性能的影响。

[0092] 数据自适应修正项为 $\varepsilon_u^*(\mathbf{x}^*)$, $\varepsilon_v^*(\mathbf{x}^*)$, $\varepsilon_p^*(\mathbf{x}^*)$,此时数据项损失变为:

$$[0093] \quad \begin{cases} L_{data_u} = u_{true}^* - \varepsilon_u^*(\mathbf{x}^*) - u_{predict}^* \\ L_{data_v} = v_{true}^* - \varepsilon_v^*(\mathbf{x}^*) - v_{predict}^* \\ L_{data_p} = p_{true}^* - \varepsilon_p^*(\mathbf{x}^*) - p_{predict}^* \end{cases}$$

[0094] 其中, L_{data_u} 为速度 u 的损失; u_{true}^* 表示采集并处理后的数据(带噪音); $\varepsilon_u^*(\mathbf{x}^*)$ 表示可训练的修正项,用于中和噪音的影响; $u_{predict}^*$ 表示神经网络预测得到的速度参量。其余物理量的含义同上。

[0095] PINNs模型的输入是无量纲化的空间坐标:

$$[0096] \quad \mathbf{x}^* = (x^*, y^*)$$

[0097] 输出为无量纲化的流函数 ψ^* 和压力 p^* ,通过对流函数求导得到无量纲速度 $\mathbf{u}^*$:

$$[0098] \quad \mathbf{u}^* = \left(\frac{\partial \psi^*}{\partial y^*}, -\frac{\partial \psi^*}{\partial x^*} \right)$$

[0099] 最终得到求解结果以及源项 $\varepsilon_u^*(\mathbf{x}^*), \varepsilon_v^*(\mathbf{x}^*), \varepsilon_p^*(\mathbf{x}^*)$:

$$[0100] \quad \mathbf{u} = U\mathbf{u}^*, p = \rho U^2 p^*。$$

[0101] 步骤3b, 模型自适应调节技术: 当数据准确, 但方程存在缺失值或简化误差时, 采用模型自适应调节技术。此技术通过引入可训练变量来弥补方程中的残缺值或修正被忽视的物理效应。如图3所示, 为基于模型自适应调节技术的神经网络算法架构, 其中, 边界条件的准确性对准确预测至关重要, 实际测量中边界条件常存在误差, 导致 R_e 数具有偏差, 从而影响预测。此时可在PINNs中添加方程修正项, 以补偿由此产生的模型偏差。同样以二维NS方程为例:

[0102] a) Navier-Stokes方程

[0103] Navier-Stokes方程的基本形式为:

$$[0104] \quad (\mathbf{u} \cdot \nabla) \mathbf{u} = -\nabla p + \nu \nabla^2 \mathbf{u}$$

$$\nabla \cdot \mathbf{u} = 0$$

[0105] 其中, $\mathbf{u}$ 表示速度矢量, p 表示压力, ν 表示运动粘性系数。

[0106] b) 流函数的引入

[0107] 针对二维不可压缩流动问题, 可以引入流函数 ψ , 使得速度矢量 $\mathbf{u}$ 可以表示为:

$$[0108] \quad \mathbf{u} = \left(\frac{\partial \psi}{\partial y}, -\frac{\partial \psi}{\partial x} \right)$$

[0109] 通过引入流函数, 自动满足了连续性方程 $\nabla \cdot \mathbf{u} = 0$, 因此只需要计算动量方程, 简化了计算过程, 降低问题的复杂性, 便于求解。

[0110] c) 数据和方程的无量纲化

[0111] 由于反应堆堆芯的复杂运行条件, 其流场压力、速度以及密度等变量数值差异较大, 影响神经网络计算的收敛性, 需对流场参数以及方程和数据进行无量纲化处理。定义无量纲变量:

$$[0112] \quad \mathbf{u}^* = \frac{\mathbf{u}}{U}, \quad p^* = \frac{p}{\rho U^2}, \quad \mathbf{x}^* = \frac{\mathbf{x}}{L}$$

[0113] 其中, U 是特征速度, L 是特征长度。经过无量纲化处理后, NS方程可以表示为:

$$[0114] \quad (\mathbf{u}^* \cdot \nabla^*) \mathbf{u}^* = -\nabla^* p^* + \frac{1}{Re} \nabla^{*2} \mathbf{u}^*$$

$$\nabla^* \cdot \mathbf{u}^* = 0$$

[0115] 其中, $Re = UL/\nu$ 是雷诺数, 表示惯性力和粘性力的比值。无量纲化处理有助于避免数值差异过大, 导致神经网络难以收敛。

[0116] d) 可训练的源项

[0117] 引入可修正源项, 修正方程偏差, 在无量纲化的NS方程中引入了一个可训练的源项 $\mathbf{v}_f$ 使得方程可以表示为:

$$[0118] \quad (\mathbf{u}^* \cdot \nabla^*) \mathbf{u}^* = -\nabla^* p^* + \left(\frac{1}{Re} + \nu_f \right) \nabla^{*2} \mathbf{u}^*$$

[0119] 该源项通过神经网络训练获得,能够自适应地调整以满足不同流场的特性和重建要求。

[0120] 此时方程损失函数变为:

$$[0121] \quad L_{equation} = (\mathbf{u}^* \cdot \nabla^*) \mathbf{u}^* + \nabla^* p^* - \left(\frac{1}{Re} + \nu_f \right) \nabla^{*2} \mathbf{u}^*$$

[0122] PINNs模型的输入是无量纲化的空间坐标:

$$[0123] \quad \mathbf{x}^* = (x^*, y^*)$$

[0124] 输出为无量纲化的流函数 ψ^* 和压力 p^* ,通过对流函数:

$$[0125] \quad \mathbf{u}^* = \left(\frac{\partial \psi^*}{\partial y^*}, -\frac{\partial \psi^*}{\partial x^*} \right)$$

[0126] 最终得到求解结果以及源项 ν_f :

$$[0127] \quad \mathbf{u} = U \mathbf{u}^*, p = \rho U^2 p^*。$$

[0128] (4) 设计用于求解的神经网络架构,明确网络的输入输出以及网络结构,具体包括:

[0129] 架构选择:设计适合的神经网络架构,并选择合适的优化算法,以支持选定的修正技术;

[0130] 输入输出设计:定义神经网络的输入和输出,确保网络能够处理和改进物理方程中的各个方面。网络输出应能够直接或通过变换计算数据损失和控制方程的损失。

[0131] (5) 根据所选择的修正技术和问题特征,定义相应形式的调节变量,具体包括:

[0132] 步骤5a,数据自适应修正:数据自适应修正:在神经网络中引入与噪声数据尺寸一致的可训练变量。这些变量可以是模型参数或网络层的输出,旨在表示数据中的噪声,并可根据已有的噪声信息,设置可训练变量的分布,并在求解中规定其阈值,以实现更加准确的修正,并避免过度修正;

[0133] 步骤5b,模型自适应调节:在神经网络中引入与模型简化相关的可训练变量,这些变量可以是单一数值或数值分布,用于弥补方程中的残缺值或修正被忽视的物理效应。

[0134] (6) 基于所选修正技术,设计模型的损失函数,具体包括:

[0135] 设计综合损失函数,包括三个主要部分:

[0136] 内部数据点损失函数:衡量模型输出与实际数据之间的差异,针对数据自适应修正技术,由于神经网络输出的物理量需与有噪声的数据进行比较;因此,通过将神经网络输出物理量与可训练的噪声变量相加,以可训练变量来中和数据的噪声,减小噪声对数据的影响,从而实现数据修正;

[0137] 边界数据点损失函数:评估模型在边界条件下的表现;

[0138] 方程损失函数:评估模型对控制方程的符合程度;对于方程中的缺失值,明确其所在位置,并在这些位置引入对应的可训练变量,此外,对于由于模型简化或计算误差导致的数据和方程的总体差异,可在方程末尾定义统一的调节参数,调节参数的尺寸应与总训练

点的尺寸一致,用于中和方程误差,并通过数据逼近量化数据与方程之间的差异。

[0139] (7) 训练并优化模型,以确保模型精度达到最高,具体包括:

[0140] 使用数据、边界条件以及自适应修正的物理方程对神经网络进行训练,直到模型收敛。并根据训练结果调整神经网络架构和优化函数,以实现最佳性能。

[0141] (8) 输出模型参数,完成对步骤(1)中提出的物理问题的求解,具体包括:

[0142] 步骤8a,数据去噪:针对数据自适应修正技术,可根据输出的用于中和数据噪声的变量确定噪声类型以及噪声分布,并可根据该变量与原始噪声数据的线性变换还原出高精度数据;

[0143] 步骤8b,方程确定:针对方程自适应调节技术,可根据神经网络迭代出的参数,确定物理方程中的缺失值或数据与方程之间的偏差值,并进行相应的修正。

[0144] 本发明在处理数据中的噪声问题时,通过在神经网络中引入可训练的变量以修正数据。该方法利用可训练变量,逼近数据中的噪声分布,从而对原始数据进行精细调整,而无需对物理模型进行修改。具体而言,数据自适应修正技术将可训练变量引入神经网络的输出的物理变量中,假设神经网络输出的物理变量为无噪声的数据变量,而可训练参数则表示数据噪声。这些可训练参数与神经网络输出的物理变量相加,用于计算数据损失项。为了确保这一过程的有效性,需要明确物理问题的初始条件、边界条件及控制方程,以便对可训练参数的迭代过程进行适当控制。这种方法的核心在于通过动态调整数据,优化数据与模型之间的匹配,从而提高数据处理和模型预测的准确性。

[0145] 与数据自适应修正技术相对应的是针对物理模型简化和方程不完备性问题的模型自适应调节技术。该技术通过在神经网络中引入可训练变量,旨在弥补方程中的残缺值或修正模型简化过程中被忽视的物理效应。这些可训练变量可以是单一数值,也可以是数值分布。具体而言,模型自适应调节技术通过在物理方程中融入这些可训练变量,以适应方程的不同调整目标。通过调节可训练变量的位置和形式,该技术能够在模型的动态调整过程中,结合数据约束对现有模型进行改进。该方法的核心在于动态调整方程中的变量,以补充参数确实以及模型简化所带来的不完备性,从而提高模型对实际物理现象的描述能力和预测准确性。

[0146] 实施例:

[0147] 将本发明所述基于数据与模型自适应修正的智能数值计算方法应用于流体力学测量的具体步骤,如下:

[0148] 步骤1:明确待计算的物理问题

[0149] 问题描述:在本实施例中,研究反应堆板元内部流体的流动行为。目标是计算流体的速度场、温度场、压力分布,并分析板元流道内的流体的流动特性。

[0150] 数据收集:通过实验测量、数值模拟获取管道内流体的速度、压力和温度数据。

[0151] 步骤2:确定系统的控制方程、边界条件与初始条件

[0152] 控制方程:质量守恒方程、动量守恒方程和能量守恒方程:

$$\frac{\partial \rho}{\partial t} + \nabla \cdot (\rho \mathbf{u}) = 0$$

$$[0153] \quad \frac{\partial(\rho \mathbf{u})}{\partial t} + \nabla \cdot (\rho \mathbf{u} \otimes \mathbf{u}) = -\nabla p + \nabla \cdot \boldsymbol{\tau} + \rho \mathbf{g}$$

$$\rho c_p \left(\frac{\partial T}{\partial t} + \mathbf{u} \cdot \nabla T \right) = k \nabla^2 T + Q$$

[0154] 其中, ρ 为密度, $\mathbf{u}$ 为速度向量, p 为压力, $\boldsymbol{\tau}$ 为应力张量, $\mathbf{g}$ 为重力; c_p 为定压比热容, T 为温度场, k 为流体的热导率, Q 为体积热源项。

[0155] 边界条件:入口:设定流速分布;出口:设定压力边界;壁面:采用无滑移条件(速度为零)。

[0156] 步骤3:选择修正技术(以数据自适应修正技术为例)

[0157] 修正技术:针对实验测量数据中的噪声,采用数据自适应修正技术。在神经网络中引入可训练变量,估计噪声分布,并进行数据去噪。

[0158] 步骤4:设计神经网络架构

[0159] 网络类型:全连接神经网络;

[0160] 输入:位置坐标和时间;

[0161] 输出:修正后的速度场、温度场和压力分布;

[0162] 网络结构:多层全连接层,用于提取流体特征并预测修正量。

[0163] 步骤5:定义调节变量

[0164] 调节变量:在神经网络中引入可训练变量 ϵ ,用于校正测量数据中的噪声;

[0165] 调节方式:在边界条件和控制方程的求解下逐渐修正噪声数据。

[0166] 步骤6:设计损失函数

$$[0167] \quad L = \lambda_1 L_{\text{data}} + \lambda_2 L_{\text{boundary}} + \lambda_3 L_{\text{equation}}$$

[0168] 其中,数据损失 L_{data} :衡量预测值与测量数据之间的差异;边界损失 L_{boundary} :确保边界条件满足物理约束;方程损失 L_{equation} :评估神经网络解对NS方程的符合程度; λ_1 、 λ_2 、 λ_3 为权重因子, $\lambda_1 + \lambda_2 + \lambda_3 = 1$ 。

[0169] 步骤7:训练并优化模型

[0170] 优化方法:采用梯度下降法或Adam优化器;

[0171] 目标:通过迭代训练,使模型精度达到最高。

[0172] 步骤8:输出模型参数

[0173] 输出结果:修正后的流体速度场和压力分布以及修正参量。

[0174] 本发明通过引入数据自适应修正和模型自适应调节技术,在反应堆板元内不可压缩流体的流动计算中实现了高精度模拟。该方法能够有效衡量实验数据中的噪声影响,同时补偿传统NS方程因简化或参数不确定性引入的误差,为核反应堆内流动、热传递及安全分析提供更加可靠的数值支撑。

[0175] 本发明还提供一种基于数据与模型自适应修正的智能数值计算系统,应用于上述的基于数据与模型自适应修正的智能数值计算方法,包括:

[0176] 数据处理模块,用于明确待计算的物理问题,收集相关数据,确定数据类型,并进行数据预处理;

[0177] 方程确定模块,用于根据所需计算的系统,确定系统的控制方程、边界条件与初始条件;

[0178] 修正技术选择模块,用于基于数据特征和方程特征,选择合适的修正技术;

[0179] 网络架构设计模块,用于设计用于求解的神经网络架构,明确神经网络架构的输入、输出以及网络结构;

[0180] 调节变量定义模块,用于根据所选择的修正技术和问题特征,定义相应形式的调节变量;

[0181] 损失函数设计模块,用于基于所选择的修正技术,设计模型的损失函数;

[0182] 模型训练模块,用于基于收集的数据、边界条件以及经修正技术修正的物理方程对神经网络架构进行训练,直到模型收敛,并根据训练结果调整神经网络架构和优化函数,得到最佳性能的模式;

[0183] 问题求解模块,用于基于最佳性能的模式,输出模型参数,完成对步骤(1)中提出的物理问题的求解。

[0184] 此外,本发明还提供种计算机可读存储介质,其上存储有计算机程序,所述计算机程序运行时执行上述的基于数据与模型自适应修正的智能数值计算方法。

[0185] 此外,本发明还提供一种计算机设备,包括存储器和处理器,所述存储器上存储有可在所述处理器上运行的计算机程序,所述处理器运行所述计算机程序时执行上述的基于数据与模型自适应修正的智能数值计算方法。

[0186] 通过以上的实施方式的描述,本领域的技术人员可以清楚地了解到各实施方式可借助软件加必需的通用硬件平台的方式来实现,当然也可以通过硬件。基于这样的理解,上述技术方案本质上或者说对现有技术做出贡献的部分可以以软件产品的形式体现出来,该计算机软件产品可以存储在计算机可读存储介质中,如ROM/RAM、磁碟、光盘等,包括若干指令用以使得一台计算机设备(可以是个人计算机,服务器,或者网络设备等)执行各个实施例或者实施例的某些部分所述的方法。

[0187] 本文中应用了具体个例对本发明的原理及实施方式进行了阐述,以上实施例的说明只是用于帮助理解本发明的方法及其核心思想;同时,对于本领域的一般技术人员,依据本发明的思想,在具体实施方式及应用范围上均会有改变之处。综上所述,本说明书内容不应理解为对本发明的限制。




图1




图2




图3