



(12) 发明专利申请

(10) 申请公布号 CN 120951784 A

(43) 申请公布日 2025. 11. 14

(21) 申请号 202511093276.3

G06F 17/12 (2006.01)

(22) 申请日 2025.08.06

G06F 111/04 (2020.01)

G06F 111/10 (2020.01)

(71) 申请人 中国核动力研究设计院

地址 610213 四川省成都市双流区长顺大道一段328号

(72) 发明人 刘东 陈奇隆 安萍 张斌

涂晓兰 邓坚 方超 江勇

潘俊杰 冯晋涛 李松岭

(74) 专利代理机构 核工业专利中心 11007

专利代理师 胡维维

(51) Int.Cl.

G06F 30/27 (2020.01)

G06F 18/214 (2023.01)

G06N 3/08 (2023.01)

G06F 17/13 (2006.01)


权利要求书4页 说明书13页 附图7页

(54) 发明名称

一种均匀系统超精细群共振自屏深度学习计算方法

(57) 摘要

本发明具体涉及一种均匀系统超精细群共振自屏深度学习计算方法,属于核反应堆堆芯计算技术领域,包括如下步骤:将完全微分形式的中子慢化方程和原函数变换方程分别映射为神经网络函数;构造中子慢化方程损失函数、原函数变换方程损伤函数、散射源原函数定解约束损失函数、能量初始条件损失函数以及通量密度非负边界条件损失函数,加权构成机器学习损失函数;根据机器学习损失函数交替调整神经网络函数参数进行迭代深度机器学习;通过将整个训练集化为一个个小训练集,并且以能量段为序依次由高向低进行训练,前一能群的训练集为后一能群的边界条件,实现中子慢化方程的分段求解。本发明实现了实现均匀系统中子慢化方程的求解新途径。



1. 一种均匀系统超精细群共振自屏深度学习计算方法,其特征在于,包括如下步骤:

步骤一、将中子慢化方程中的散射源积分项升阶为完全微分形式,得到完全微分形式的中子慢化方程;将完全微分形式的中子慢化方程中的中子通量和散射源积分项升阶形式分别映射为神经网络函数;

步骤二、将神经网络函数作为试函数分别代入完全微分形式的中子慢化方程和原函数变换方程,得到中子慢化方程损失函数和原函数变换方程损伤函数;构造散射源原函数定解约束损失函数、能量初始条件损失函数以及通量密度非负边界条件损失函数;

步骤三、将中子慢化方程损失函数、原函数变换方程损失函数、散射源原函数定解约束损失函数、能量初始条件损失函数以及通量密度非负边界条件损失函数加权构成机器学习损失函数;

步骤四、根据机器学习损失函数交替调整神经网络函数参数进行迭代深度机器学习;

步骤五、在步骤四的基础上,通过将整个训练集化为一个个小训练集,并且以能量段为序依次由高向低进行训练,前一能群的训练集为后一能群的边界条件,实现中子慢化方程的分段求解。

2. 根据权利要求1所述的均匀系统超精细群共振自屏深度学习计算方法,其特征在于,步骤一中,一个核素对应两个神经网络函数,其中一个为完全微分形式的中子慢化方程的神经网络函数,另一个为核素原函数变换方程的神经网络函数;每多一种核素,会多一种原函数变换方程的神经网络函数。

3. 根据权利要求1所述的均匀系统超精细群共振自屏深度学习计算方法,其特征在于,均匀系统为无限均匀系统,步骤一中,中子慢化方程为包含中子反应截面与中子通量密度的组合函数:

$$\Sigma_t(u)\phi(u) = \sum_k \int_{u-\ln \frac{1}{\alpha_k}}^u \frac{N_k \sigma_{s,k}(u')\phi(u')}{1-\alpha_k} e^{u'-u} du' \quad (1)$$

将中子慢化方程中的散射源积分项通过Newton-Leibniz公式升阶为完全微分形式,得到完全微分形式的中子慢化方程:

$$\Sigma_t(u)\phi(u) = e^{-u} \sum_k \left[F_{k,0}(u) - F_{k,0}\left(u - \ln \frac{1}{\alpha_k}\right) \right] \quad (8)$$

其中, Σ_t 为中子反应截面函数, ϕ 为中子通量密度函数, k 为多个核素的编号; N_k 为核素 k 的核子密度, $\sigma_{s,k}$ 为核素 k 的微观弹性散射截面, $\sigma_{s,k}$ 为散射截面, α_k 为核素 k 的 α 值; u 为对数能降, u' 为被积对数能降。

4. 根据权利要求1所述的均匀系统超精细群共振自屏深度学习计算方法,其特征在于,步骤一中,神经网络函数为全连接深度神经网络函数:

$$N(x) = f(x, w, b, l, n) \quad (3)$$

其中, $N(x)$ 为神经网络的输出向量; x 为神经网络的输入向量,包括中子慢化方程、原函数变换方程、散射源原函数定解约束条件、能量初始条件和通量密度非负边界条件; w 为神经网络的连接权重; b 为神经网络的偏置项; l 为神经网络的深度; n 为神经网络的隐藏神经单元个数; f 为激活函数。

5. 根据权利要求1所述的均匀系统超精细群共振自屏深度学习计算方法,其特征不在于,中子慢化方程求解的约束条件方程组为:

$$\left\{ \begin{array}{l} M(u) = e^{-u} \sum_{k=1} \left[F_{k,0}(u) - F_{k,0} \left(u - \ln \frac{1}{\alpha_k} \right) \right] \\ F_{k,0}'(u) = \frac{N_k \sigma_{s,k}(u) M(u)}{(1 - \alpha_k) \Sigma_t(u)} e^u \\ u = 0, F_{k,0}(0) = 0 \\ M(u) / \Sigma_t(u_0) = C_0, 0 < u < u_0 \\ M(u) > 0, F_{k,0}(u) > 0 \end{array} \right. \quad (10)。$$

6. 根据权利要求5所述的均匀系统超精细群共振自屏深度学习计算方法,其特征不在于,中子慢化方程损失函数为:

$$Loss_{M^f} = \frac{1}{|i|} \sum_i \left[N_M(x_u^i) - e^{-u} \sum_k \left[N_{F_{k,0}}(x_u^i) - N_{F_{k,0}} \left(x_u^i - \ln \frac{1}{\alpha_k} \right) \right] \right]^2 \quad (11)$$

原函数变换方程损失函数为:

$$Loss_{F_{k,0}^d} = \frac{1}{|i|} \sum_i \left[N_{F_{k,0}}'(x_u^i) - \frac{N_k \sigma_{s,k}(u^i) N_M(x_u^i)}{(1 - \alpha_k) \Sigma_t(u^i)} e^{u^i} \right]^2 \quad (12)$$

其中,i为机器学习所需要的样本点,按照一定的概率密度分布方法生成;散射源原函数定解约束损失函数为:

$$Loss_{F_{k,0}^a} = \left[N_{F_{k,0}}(0) - F_{k,0}(0) \right]^2 = \left[N_{F_{k,0}}(0) \right]^2 \quad (13)$$

能量初始条件损失函数为:

$$Loss_{M^{b_u}} = \frac{1}{|j|} \sum_j \left[\frac{N_M(x_u^j)}{\Sigma_t(u_0)} - C_0 \right]^2, 0 < x_u^j < u_0 \quad (14)$$

$$Loss_{F_{k,0}^{b_u}} = \frac{1}{|j|} \sum_j \left[N_{F_{k,0}}'(x_u^j) - \frac{N_k \sigma_{s,k}(u_0) N_M(x_u^j)}{(1 - \alpha_k) \Sigma_t(u_0)} e^{u^j} \right]^2, 0 < x_u^j < u_0 \quad (15)$$

其中,j为 $0 < u < u_0$ 之间的机器学习样本点;

通量密度非负边界条件损失函数为:

$$Loss_{M^{b_{abs}}} = \frac{1}{|i|} \sum_i \left[N_M(x_u^i) - \text{abs}(N_M(x_u^i)) \right]^2 \quad (16)$$

$$Loss_{F_{k,0}^{b_{abs}}} = \frac{1}{|i|} \sum_i \left[N_{F_{k,0}}(x_u^i) - \text{abs}(N_{F_{k,0}}(x_u^i)) \right]^2 \quad (17)$$

式中,abs()为取绝对值函数。

7. 根据权利要求1所述的均匀系统超精细群共振自屏深度学习计算方法,其特征不在于,针对组合函数M(u)对应的神经网络 $N_M(x_u)$,选择慢化方程及相应的边界条件损失函数进行

加权,得到加权后的单一损失函数:

$$Loss_{M^{all}} = P_{M^f} Loss_{M^f} + P_{M^{bu}} Loss_{M^{bu}} + P_{M^{babs}} Loss_{M^{babs}} \quad (18)$$

式中, P_{M^f} 、 $P_{M^{bu}}$ 、 $P_{M^{babs}}$ 分别为中子慢化方程损失函数、能量初始条件损失函数、非负边界条件损失函数对应的权重,根据试验与经验系数确定值。

8. 根据权利要求1所述的均匀系统超精细群共振自屏深度学习计算方法,其特征在于,对散射源原函数方程对应的不同神经网络函数 $N_{F_{k,0}}(x_u)$, 分别选择相应的原函数变换方程、确定解约束、能量初始条件、非负边界条件构造加权损失函数,得到:

$$Loss_{F_{k,0,all}} = P_{F_{k,0}^d} Loss_{F_{k,0}^d} + P_{F_{k,0}^a} Loss_{F_{k,0}^a} + P_{F_{k,0}^{bu}} Loss_{F_{k,0}^{bu}} + P_{F_{k,0}^{babs}} Loss_{F_{k,0}^{babs}} \quad (19)$$

式中, $P_{F_{k,0}^d}$ 、 $P_{F_{k,0}^a}$ 、 $P_{F_{k,0}^{bu}}$ 、 $P_{F_{k,0}^{babs}}$ 分别为核素k对应的积分项原函数变换方程损失函数、确定解约束损失函数、能量初始条件损失函数、非负边界条件损失函数对应的权重。

9. 根据权利要求8所述的均匀系统超精细群共振自屏深度学习计算方法,其特征在于,式(19)中若用同一个神经网络的多个输出分别表示不同核素对应的 $F_{k,0}(u)$, 则总体的损失函数表示为:

$$Loss_{F_{0,all}} = \sum_{k=1}^K (P_{F_{k,0}^d} Loss_{F_{k,0}^d} + P_{F_{k,0}^a} Loss_{F_{k,0}^a} + P_{F_{k,0}^{bu}} Loss_{F_{k,0}^{bu}} + P_{F_{k,0}^{babs}} Loss_{F_{k,0}^{babs}}) \quad (20)$$

10. 根据权利要求1所述的均匀系统超精细群共振自屏深度学习计算方法,其特征在于,步骤一中,将式(4)关于¹H的积分项进行处理,以求解域最高点能量上限的对数能降 u_0 为分界点将¹H的积分项进行拆分,得到:

$$\begin{aligned} \int_{u-\ln \frac{1}{\alpha_H}}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'-u} du' &= \int_{-\infty}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'-u} du' \\ &= e^{-u} \left(\int_{-\infty}^{u_0} \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \\ &= e^{-u} \left(\frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} \int_{-\infty}^{u_0} e^{u'} du' + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \\ &= e^{-u} \left(\frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} e^{u_0} + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \end{aligned}$$

对第一项进行简化,将积分号内的常数项取出,最终积分号下只剩下 $e^{u'}$ 这一项,直接进行积分得到解析解;由式(21)可得中子慢化方程损失函数为:

$$Loss_{\phi} = \frac{1}{|i|} \sum_i \left[N_{\phi}(\vec{x}_i) - e^{-\vec{x}_i} \left[\begin{aligned} &N_U(\vec{x}_i) - N_U \left(\vec{x}_i - \ln \frac{1}{\alpha_U} \right) + \\ &N_H(\vec{x}_i) - N_H(u_0) + A \end{aligned} \right] \right] \quad (22)$$

$$A = \frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} e^{u_0} \quad (23)$$

其余损失函数保持不变。

11. 根据权利要求1所述的均匀系统超精细群共振自屏深度学习计算方法,其特征在
于,在实际训练过程中,假设第m群的对数能降范围为 $u_{m-1}:u_m$, B_{m-1} 为 $u_{m-2}:u_{m-1}$ 范围内的某一
常数;用 $N_{\phi,m}$ 和 $N_{k,0,m}$ 代表第m群的神经网络函数,则边界条件损失函数为:

$$Loss_{b,\phi} = \frac{1}{|j|} \sum_j \left[N_{\phi,m}(\vec{x}_j) - N_{\phi,m-1}(\vec{x}_j) \right]^2, B_{m-1} < \vec{x}_j < u_{m-1} \quad (24)$$

$$Loss_{b,F,k} = \frac{1}{|j|} \sum_j \left[N_{k,0,m}(\vec{x}_j) - N_{k,0,m-1}(\vec{x}_j) \right]^2, B_{m-1} < \vec{x}_j < u_{m-1} \quad (25)$$

式中,j为机器学习所需要的样本点。

12. 根据权利要求11所述的均匀系统超精细群共振自屏深度学习计算方法,其特征在
于,将边界条件损失函数(24)和(25)替代能量初始条件和原函数定解约束函数进行加权,
得到针对 $N_{\phi}(\vec{x})$ 深度学习损失函数 $Loss_{\phi-all}$,以及针对 $N_{k,0}(\vec{x})$ 的损失函数:

$$Loss_{\phi-all} = P_{\phi} Loss_{\phi} + P_{b,\phi} Loss_{b,\phi} + P_{\phi-abs} Loss_{\phi-abs} \quad (26)$$

$$Loss_{p-all-k} = P_p Loss_p + P_{b,F,k} Loss_{b,F,k} + P_{p-abs-k} Loss_{p-abs-k} \quad (27)$$

式中, P_{ϕ} , $P_{b,\phi}$, $P_{\phi-abs}$, P_p , $P_{b,F,k}$, $P_{p-abs-k}$ 分别为对应损失函数的权重,其中, $Loss_{p-all-k}$ 是
假设存在多个原函数的情况,也就是核素数量大于等于2的情况。

一种均匀系统超精细群共振自屏深度学习计算方法

技术领域

[0001] 本发明涉及核反应堆堆芯计算技术领域,特别是涉及一种均匀系统超精细群共振自屏深度学习计算方法。

背景技术

[0002] 共振自屏计算是反应堆物理分析与堆芯设计关键领域,它为中子输运计算提供了重要的共振能群有效截面,其中求解中子慢化方程是共振自屏计算的核心环节。当前,常用的共振计算方法包括等价理论和子群方法,这些方法具有较高的计算效率,目前已经得到广泛应用。但是,由于等价理论采用了一系列针对特定几何的简化模型,使得该方法缺乏处理复杂几何形状的能力;而子群方法在生成子群参数时也常常会遇到数值不稳定问题。

[0003] 与此同时,在传统共振自屏计算方法中,超精细群方法是公认的高精度方法,它在极其细致的能群结构中求解慢化方程,以获得近似于连续能量的精确慢化能谱,在能谱适应性、共振干涉效应处理等方面均具有独特的优势。特别是近年来发展起来的超精细群方法与特征线法(MOC)结合的技术,能在几乎连续能量结构基础上处理复杂的几何效应,使得这种方法往往作为其他多群方法的计算基准。然而,当前的超精细群方法依然存在计算效率不高、处理几何形式受限等困难,主要用于共振积分的产生、多群共振方法在特定条件下的基准计算,以及局部区域的截面修正,尚未直接应用于大规模反应堆堆芯工程设计。

[0004] 当前,随着人工智能技术的飞速发展,深度学习求解微分方程的数值计算方法取得了长足进步,也已经在求解反应堆物理中子扩散方程、输运方程等领域均取得了显著的成果,并在控制方程模型完整性、无网格方程离散、计算结果连续性等方面表现出一系列潜在优势,这为超精细群共振自屏计算提供了新的技术途径。利用深度学习方法进行共振自屏计算已有初步的研究,其主要技术路线是通过数据驱动的方式形成共振自屏计算的机器学习代理模型,进而实现计算加速,该技术路线需要事先获得传统方法的计算结果作为深度学习的机器学习样本,具有一定的局限性。

[0005] 为此,本发明采用深度学习计算方法,针对无限均匀系统中子慢化方程进行直接求解,提出组合函数变阶迭代深度学习计算方法,将慢化能谱与总截面相乘后形成组合函数,以减小慢化能谱高频振荡特点对神经网络函数数值逼近性能的影响,建立一种新型求解均匀系统慢化方程数值的方法。

发明内容

[0006] 本发明的目的在于,提供一种均匀系统超精细群共振自屏深度学习计算方法,将物理模型驱动的PINN方法与传统共振自屏计算的超精细群方法相结合,并采用组合函数变阶迭代深度学习,将慢化能谱与总截面相乘后形成组合函数,以减小慢化能谱高频振荡特点对神经网络函数数值逼近性能的影响,实现均匀系统中子慢化方程的求解,从而实现具有共振干涉条件下的慢化能谱计算,为反应堆共振自屏计算方提供了新的技术途径。

[0007] 为了实现上述目的,本发明提供如下技术方案:

[0008] 一种均匀系统超精细群共振自屏深度学习计算方法,包括如下步骤:

[0009] 步骤一、将中子慢化方程中的散射源积分项升阶为完全微分形式,得到完全微分形式的中子慢化方程;将完全微分形式的中子慢化方程中的中子通量和散射源积分项升阶形式分别映射为神经网络函数;

[0010] 步骤二、将神经网络函数作为试函数分别代入完全微分形式的中子慢化方程和原函数变换方程,得到中子慢化方程损失函数和原函数变换方程损伤函数;构造散射源原函数定解约束损失函数、能量初始条件损失函数以及通量密度非负边界条件损失函数;

[0011] 步骤三、将中子慢化方程损失函数、原函数变换方程损失函数、散射源原函数定解约束损失函数、能量初始条件损失函数以及通量密度非负边界条件损失函数加权构成机器学习损失函数;

[0012] 步骤四、根据机器学习损失函数交替调整神经网络函数参数进行迭代深度机器学习;

[0013] 步骤五、在步骤四的基础上,通过将整个训练集化为一个个小训练集,并且以能量段为序依次由高向低进行训练,前一能群的训练集为后一能群的边界条件,实现中子慢化方程的分段求解。

[0014] 作为其中一种可实现的方式,步骤一中,一个核素对应两个神经网络函数,其中一个为完全微分形式的中子慢化方程的神经网络函数,另一个为核素原函数变换方程的神经网络函数;每多一种核素,会多一种原函数变换方程的神经网络函数。

[0015] 作为其中一种可实现的方式,均匀系统为无限均匀系统,步骤一中,中子慢化方程为包含中子反应截面与中子通量密度的组合函数:

$$[0016] \quad \Sigma_t(u)\phi(u) = \sum_k \int_{u-\ln \frac{1}{\alpha_k}}^u \frac{N_k \sigma_{s,k}(u')\phi(u')}{1-\alpha_k} e^{u'-u} du' \quad (1)$$

[0017] 将中子慢化方程中的散射源积分项通过Newton-Leibniz公式升阶为完全微分形式,得到完全微分形式的中子慢化方程:

$$[0018] \quad \Sigma_t(u)\phi(u) = e^{-u} \sum_k \left[F_{k,0}(u) - F_{k,0}\left(u - \ln \frac{1}{\alpha_k}\right) \right] \quad (8)$$

[0019] 其中, Σ_t 为中子反应截面函数, ϕ 为中子通量密度函数, k 为多个核素的编号; N_k 为核素 k 的核子密度, $\sigma_{s,k}$ 为核素 k 的微观弹性散射截面, $\sigma_{s,k}$ 为散射截面, α_k 为核素 k 的 α 值; u 为对数能降, u' 为被积对数能降。

[0020] 作为其中一种可实现的方式,步骤一中,神经网络函数为全连接深度神经网络函数:

$$[0021] \quad N(x) = f(x, w, b, l, n) \quad (3)$$

[0022] 其中, $N(x)$ 为神经网络的输出向量; x 为神经网络的输入向量,包括中子慢化方程、原函数变换方程、散射源原函数定解约束条件、能量初始条件和通量密度非负边界条件; w 为神经网络的连接权重; b 为神经网络的偏置项; l 为神经网络的深度; n 为神经网络的隐藏神经单元个数; f 为激活函数。

[0023] 作为其中一种可实现的方式,中子慢化方程求解的约束条件方程组为:

$$[0024] \quad \left\{ \begin{array}{l} M(u) = e^{-u} \sum_{k=1} \left[F_{k,0}(u) - F_{k,0} \left(u - \ln \frac{1}{\alpha_k} \right) \right] \\ F_{k,0}(u)' = \frac{N_k \sigma_{s,k}(u) M(u)}{(1-\alpha_k) \Sigma_t(u)} e^u \\ u=0, F_{k,0}(0)=0 \\ M(u)/\Sigma_t(u_0)=C_0, 0 < u < u_0 \\ M(u) > 0, F_{k,0}(u) > 0 \end{array} \right. \quad (10)$$

[0025] 作为其中一种可实现的方式,中子慢化方程损失函数为:

$$[0026] \quad Loss_{M^f} = \frac{1}{|i|} \sum_i \left[N_M(x_u^i) - e^{-u} \sum_k \left[N_{F_{k,0}}(x_u^i) - N_{F_{k,0}} \left(x_u^i - \ln \frac{1}{\alpha_k} \right) \right] \right]^2 \quad (11)$$

[0027] 其中,i为机器学习所需要的样本点,按照一定的概率密度分布方法生成。

[0028] 作为其中一种可实现的方式,原函数变换方程损失函数为:

$$[0029] \quad Loss_{F_{k,0}^d} = \frac{1}{|i|} \sum_i \left[N_{F_{k,0}}(x_u^i)' - \frac{N_k \sigma_{s,k}(u^i) N_M(x_u^i)}{(1-\alpha_k) \Sigma_t(u^i)} e^{u^i} \right]^2 \quad (12)$$

[0030] 其中,式(12)机器学习样本的取值范围与式(11)相同。

[0031] 作为其中一种可实现的方式,散射源原函数定解约束损失函数为:

$$[0032] \quad Loss_{F_{k,0}^a} = \left[N_{F_{k,0}}(0) - F_{k,0}(0) \right]^2 = \left[N_{F_{k,0}}(0) \right]^2 \quad (13)。$$

[0033] 作为其中一种可实现的方式,能量初始条件损失函数为:

$$Loss_{M^{b_u}} = \frac{1}{|j|} \sum_j \left[\frac{N_M(x_u^j)}{\Sigma_t(u_0)} - C_0 \right]^2, 0 < x_u^j < u_0 \quad (14)$$

[0034]

$$Loss_{F_{k,0}^{b_u}} = \frac{1}{|j|} \sum_j \left[N_{F_{k,0}}'(x_u^j) - \frac{N_k \sigma_{s,k}(u_0) N_M(x_u^j)}{(1-\alpha_k) \Sigma_t(u_0)} e^{u^j} \right]^2, 0 < x_u^j < u_0 \quad (15)$$

[0035] 其中,j为0<u<u₀之间的机器学习样本点。

[0036] 作为其中一种可实现的方式,通量密度非负边界条件损失函数为:

$$Loss_{M^{b_{abs}}} = \frac{1}{|i|} \sum_i \left[N_M(x_u^i) - abs(N_M(x_u^i)) \right]^2 \quad (16)$$

[0037]

$$Loss_{F_{k,0}^{b_{abs}}} = \frac{1}{|i|} \sum_i \left[N_{F_{k,0}}(x_u^i) - abs(N_{F_{k,0}}(x_u^i)) \right]^2 \quad (17)$$

[0038] 式中,abs()为取绝对值函数。

[0039] 作为其中一种可实现的方式,针对组合函数M(u)对应的神经网络N_M(x_u),选择慢化方程及相应的边界条件损失函数进行加权,得到加权后的单一损失函数:

$$[0040] \quad Loss_{M^{all}} = P_{M^f} Loss_{M^f} + P_{M^{b_u}} Loss_{M^{b_u}} + P_{M^{b_{abs}}} Loss_{M^{b_{abs}}} \quad (18)$$

[0041] 式中, P_{M^f} 、 $P_{M^{bu}}$ 、 $P_{M^{babs}}$ 分别为中子慢化方程损失函数、能量初始条件损失函数、非负边界条件损失函数对应的权重,根据试验与经验系数确定值。

[0042] 作为其中一种可实现的方式,对散射源原函数方程对应的不同神经网络函数 $N_{F_{k,0}}(x_u)$,分别选择相应的原函数变换方程、确定解约束、能量初始条件、非负边界条件构造加权损失函数,得到:

$$[0043] \quad Loss_{F_{k,0},all} = P_{F_{k,0}^d} Loss_{F_{k,0}^d} + P_{F_{k,0}^a} Loss_{F_{k,0}^a} + P_{F_{k,0}^{bu}} Loss_{F_{k,0}^{bu}} + P_{F_{k,0}^{babs}} Loss_{F_{k,0}^{babs}} \quad (19)$$

[0044] 式中, $P_{F_{k,0}^d}$ 、 $P_{F_{k,0}^a}$ 、 $P_{F_{k,0}^{bu}}$ 、 $P_{F_{k,0}^{babs}}$ 分别为核素k对应的积分项原函数变换方程损失函数、确定解约束损失函数、能量初始条件损失函数、非负边界条件损失函数对应的权重。

[0045] 作为其中一种可实现的方式,式(19)中若用同一个神经网络的多个输出分别表示不同核素对应的 $F_{k,0}(u)$,则总体的损失函数表示为:

$$[0046] \quad Loss_{F_{0,all}} = \sum_{k=1}^K (P_{F_{k,0}^d} Loss_{F_{k,0}^d} + P_{F_{k,0}^a} Loss_{F_{k,0}^a} + P_{F_{k,0}^{bu}} Loss_{F_{k,0}^{bu}} + P_{F_{k,0}^{babs}} Loss_{F_{k,0}^{babs}}) \quad (20)。$$

[0047] 作为其中一种可实现的方式,步骤一中,将式(4)关于¹H的积分项进行处理,以求解域最高点能量上限的对数能降 u_0 为分界点将¹H的积分项进行拆分,得到:

$$[0048] \quad \begin{aligned} \int_{u-\ln \frac{1}{\alpha_H}}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'-u} du' &= \int_{-\infty}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'-u} du' \\ &= e^{-u} \left(\int_{-\infty}^{u_0} \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \\ &= e^{-u} \left(\frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} \int_{-\infty}^{u_0} e^{u'} du' + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \quad (21) \\ &= e^{-u} \left(\frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} e^{u_0} + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \end{aligned}$$

[0049] 对第一项进行简化,将积分号内的常数项取出,最终积分号下只剩下 $e^{u'}$ 这一项,直接进行积分得到解析解;由式(21)可得中子慢化方程损失函数为:

$$[0050] \quad Loss_{\phi} = \frac{1}{|i|} \sum_i \left[N_{\phi}(\mathbf{x}_i) - e^{-\frac{\mathbf{r}}{x_i}} \left[\begin{aligned} &N_U(\mathbf{x}_i) - N_U \left(\mathbf{x}_i - \ln \frac{1}{\alpha_U} \right) + \\ &N_H(\mathbf{x}_i) - N_H(u_0) + A \end{aligned} \right] \right] \quad (22)$$

$$A = \frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} e^{u_0} \quad (23)$$

[0051] 其余损失函数保持不变。

[0052] 作为其中一种可实现的方式,在实际训练过程中,假设第m群的对数能降范围为 $u_{m-1}:u_m$, B_{m-1} 为 $u_{m-2}:u_{m-1}$ 范围内的某一常数;用 $N_{\phi,m}$ 和 $N_{k,0,m}$ 代表第m群的神经网络函数,则边界条件损失函数为:

$$Loss_{b,\phi} = \frac{1}{|j|} \sum_j \left[N_{\phi,m}(\mathbf{r}_{x_j}) - N_{\phi,m-1}(\mathbf{r}_{x_j}) \right]^2, B_{m-1} < \mathbf{r}_{x_j} < u_{m-1} \quad (24)$$

[0053]

$$Loss_{b,F,k} = \frac{1}{|j|} \sum_j \left[N_{k,0,m}(\mathbf{r}_{x_j}) - N_{k,0,m-1}(\mathbf{r}_{x_j}) \right]^2, B_{m-1} < \mathbf{r}_{x_j} < u_{m-1} \quad (25)$$

[0054] 式中, j为机器学习所需要的样本点。

[0055] 作为其中一种可实现的方式, 将边界条件损失函数 (24) 和 (25) 替代能量初始条件和原函数定解约束函数进行加权, 得到针对 $N_{\phi}(\mathbf{r})$ 深度学习损失函数 $Loss_{\phi-all}$, 以及针对 $N_{k,0}(\mathbf{r})$ 的损失函数:

$$Loss_{\phi-all} = P_{\phi} Loss_{\phi} + P_{b,\phi} Loss_{b,\phi} + P_{\phi-abs} Loss_{\phi-abs} \quad (26)$$

$$Loss_{p-all-k} = P_p Loss_p + P_{b,F,k} Loss_{b,F,k} + P_{p-abs-k} Loss_{p-abs-k} \quad (27)$$

[0058] 式中, P_{ϕ} , $P_{b,\phi}$, $P_{\phi-abs}$, P_p , $P_{b,F,k}$, $P_{p-abs-k}$ 分别为对应损失函数的权重, 其中, $Loss_{p-all-k}$ 是假设存在多个原函数的情况, 也就是核素数量大于等于2的情况。

[0059] 本发明的有益技术效果:

[0060] 本发明的均匀系统超精细群共振自屏深度学习计算方法, 将物理模型驱动的PINN方法与传统共振自屏计算的超精细群方法相结合, 并采用组合函数变阶迭代深度学习, 将慢化能谱与总截面相乘后形成组合函数, 以减小慢化能谱高频振荡特点对神经网络函数数值逼近性能的影响, 实现均匀系统中子慢化方程的求解, 从而实现具有共振干涉条件下的慢化能谱计算; 通过多个均匀系统算例进行数值计算, 验证了所提出的方法原理及计算流程的正确性, 并具有解决多核素共振干涉问题的能力, 验证计算结果得到了慢化能谱随能量的连续分布, 证明了所提出的方法在慢化能谱局部特性分辨能力上具有潜在优势, 探索了求解中子慢化方程的新方式。

附图说明

[0061] 图1为²³⁵U慢化能谱、截面与组合函数的共振峰特性示意图;

[0062] 图2为均匀系统超精细群共振自屏深度学习计算方法的一个实施例的流程示意图;

[0063] 图3为²³⁸U和¹⁶O构造均匀系统的总截面的相对偏差分布示意图;[0064] 图4为²³⁸U和¹⁶O构造均匀系统的连续能量能谱对比示意图;

[0065] 图5为组合函数M(u)随对数能量的变化趋势示意图;

[0066] 图6为²³⁸U和¹⁶O对应的积分原函数 $F_{k,0}(u)$ 的计算结果示意图;[0067] 图7为²³⁸U和¹H构造均匀系统总截面的相对误差分布示意图;[0068] 图8为²³⁸U和¹H构造均匀系统的15-18群能量能谱对比示意图;[0069] 图9为²³⁸U和¹H对应的积分原函数 $F_{k,0}(u)$ 计算结果示意图;[0070] 图10(a)为²³⁵U微观共振散射截面的对比及偏差分布示意图;[0071] 图10(b)为²³⁸U微观共振散射截面的对比及偏差分布示意图;[0072] 图10(c)为²³⁵U、²³⁸U和¹⁶O构造均匀系统的总截面的相对偏差分布示意图;[0073] 图11为²³⁵U、²³⁸U和¹⁶O对应的积分原函数 $F_{k,0}(u)$ 计算结果示意图;

- [0074] 图12(a)为 ^{239}Pu 微观共振散射截面的对比及相对偏差分布示意图；
[0075] 图12(b)为 ^{90}Zr 微观共振散射截面的对比及相对偏差分布示意图；
[0076] 图12(c)为 ^{238}U 微观共振散射截面的对比及相对偏差分布示意图；
[0077] 图13为238U、160、90Zr和239Pu对应的积分原函数 $F_{k,0}(u)$ 计算结果示意图。

具体实施方式

[0078] 除非另有定义,本文所使用的所有的技术和科学术语与属于本申请的技术领域的技术人员通常理解的含义相同;本文在申请的说明书中所使用的术语只是为了描述具体的实施例的目的,不是旨在于限制本申请。

[0079] 在本文中提及“实施例”意味着,结合实施例描述的特定特征、结构或特性可以包含在本申请的至少一个实施例中。在说明书中的各个位置出现该短语并不一定均是指相同的实施例,也不是与其它实施例互斥的独立的或备选的实施例。本领域技术人员显式地和隐式地理解的是,本文所描述的实施例可以与其它实施例相结合。

[0080] 术语“包括”、“包含”或者其任何其他变体,意在涵盖非排他性的包含,除了包含所列的那些要素,而且还可包含没有明确列出的其他要素。

[0081] 下面结合附图和具体实施例对本发明的技术方案进行清楚、完整地描述。

[0082] 本实施例提供一种均匀系统超精细群共振自屏深度学习计算方法,包括如下步骤:

[0083] 步骤一、将中子慢化方程中的散射源积分项升阶为完全微分形式,得到完全微分形式的中子慢化方程;将完全微分形式的中子慢化方程中的中子通量和散射源积分项升阶形式分别映射为神经网络函数;

[0084] 步骤二、将神经网络函数作为试函数分别代入完全微分形式的中子慢化方程和原函数变换方程,得到中子慢化方程损失函数和原函数变换方程损伤函数;构造散射源原函数定解约束损失函数、能量初始条件损失函数以及通量密度非负边界条件损失函数;

[0085] 步骤三、将中子慢化方程损失函数、原函数变换方程损失函数、散射源原函数定解约束损失函数、能量初始条件损失函数以及通量密度非负边界条件损失函数加权构成统一的机器学习损失函数;

[0086] 步骤四、根据机器学习损失函数交替调整神经网络函数参数进行迭代深度机器学习;

[0087] 步骤五、在步骤四的基础上,通过将整个训练集化为一个个数据量合适的小训练集,并且以能量段为序依次由高向低进行训练,前一能群的训练集为后一能群的边界条件,实现中子慢化方程的分段求解。

[0088] 本实施例中,作为其中一种可实现的方式,步骤一中,一个核素对应两个神经网络函数,其中一个为完全微分形式的中子慢化方程的神经网络函数,另一个为核素原函数变换方程的神经网络函数;每多一种核素,会多一种原函数变换方程的神经网络函数。

[0089] 本实施例中,作为其中一种可实现的方式,均匀系统为无限均匀系统,步骤一中,中子慢化方程为包含中子反应截面与中子通量密度的组合函数:

$$[0090] \quad \Sigma_t(u)\phi(u) = \sum_k \int_{u-\ln\frac{1}{\alpha_k}}^u \frac{N_k \sigma_{s,k}(u')\phi(u')}{1-\alpha_k} e^{u'-u} du' \quad (1)$$

[0091] 其中, Σ_t 为中子反应截面函数, ϕ 为中子通量密度函数, k 为多个核素的编号; N_k 为核素 k 的核子密度, $\sigma_{s,k}$ 为核素 k 的微观弹性散射截面, $\sigma_{s,k}$ 为散射截面, u 为对数能降; u' 为被积对数能降; α_k 为核素 k 的 α 值; 对数能降表达式如下:

$$[0092] \quad u = \ln \frac{E_0}{E}$$

[0093] 共振自屏计算的关键中子学特性是在共振能量范围内, 尤其是反应堆中常见的较大原子量的核素, 中子反应截面呈现出剧烈的波动。在某些能量点附近, 可以观察到中子反应截面呈现出一种“峰”状的形态, 其波动的跨度会高到数个数量级。由于中子反应截面共振峰的存在, 该能量点附近的中子发生反应的概率非常大, 而对应的中子通量往往呈现出一个低谷, 造成中子在此处的反应率很小, 即存在所谓的共振自屏现象。图1给出均匀系统总输运截面及慢化能谱随能量的变化, 可以看到总截面及对应的中子慢化能谱的共振峰。

[0094] 从图1可以看出, 共振核素中子反应截面大小与中子通量密度具有呈反比的特性, 即在中子反应截面很大情况, 中子通量密度通常较小, 而对应中子反应截面不存在共振峰的地方, 中子通量密度反而较大。针对无限均匀系统中的中子慢化方程, 将中子反应截面函数与中子通量密度函数相乘, 得到包含中子反应截面与中子通量密度的组合函数 $M(u)$:

$$[0095] \quad M(u) = \Sigma_t(u) \phi(u) \quad (2)$$

[0096] 组合函数 $M(u)$ 幅值的波动程度相对于中子反应截面函数 $\Sigma_t(u)$ 与中子通量密度函数 $\phi(u)$ 幅值的波动程度将大幅减小, 减小深度学习求解过程中慢化能谱高频特征带来的不利影响。

[0097] 本实施例中, 作为其中一种可实现的方式, 步骤一中, 将中子慢化方程中的散射源积分项通过Newton-Leibniz公式升阶为完全微分形式, 得到完全微分形式的中子慢化方程, 具体包括如下步骤:

[0098] 中子慢化方程中的散射源积分项为:

$$[0099] \quad \int_{u-\ln\frac{1}{\alpha_k}}^u \frac{N_k \sigma_{s,k}(u')\phi(u')}{1-\alpha_k} e^{u'-u} du' = e^{-u} \int_{u-\ln\frac{1}{\alpha_k}}^u \frac{N_k \sigma_{s,k}(u')\phi(u')}{1-\alpha_k} e^{u'} du' \quad (4)$$

[0100] 式(4)中的中子通量密度函数 $\phi(u')$ 、核子密度 N_k 、散射截面 $\sigma_{s,k}(u')$ 是连续的, 则积分号下的被积函数也是连续的, 存在关于 u' 的积分原函数 $F_k(u')$, 其关于 u' 的导数计为:

$$[0101] \quad F_k(u')' = \frac{dF_k(u')}{du'} = \frac{N_k \sigma_{s,k}(u')\phi(u')}{1-\alpha_k} e^{u'} \quad (5)$$

[0102] 另由Newton-Leibniz公式有:

$$[0103] \quad \int_{u-\ln\frac{1}{\alpha_k}}^u \frac{N_k \sigma_{s,k}(u')\phi(u')}{1-\alpha_k} e^{u'} du' = F_k(u) - F_k\left(u - \ln\frac{1}{\alpha_k}\right) \quad (6)$$

[0104] 式(6)中原函数 $F_k(u)$ 不是确定的, 是由一簇导数相等的函数簇组成, 需要确定原函数 $F_k(u)$ 具体形式, 式(6)才有解, 给出 $F_k(u)$ 一种简洁确定解的约束条件:

[0105] $u=0, F_{k,0}(0)=0$ (7)

[0106] 由此,将式(6)和(7)代入式(1)形成完全微分形式的中子慢化方程:

$$[0107] \quad \Sigma_t(u)\phi(u) = e^{-u} \sum_k \left[F_{k,0}(u) - F_{k,0}\left(u - \ln \frac{1}{\alpha_k}\right) \right] \quad (8)$$

[0108] 本实施例中,作为其中一种可实现的方式,步骤一中,神经网络函数为全连接深度神经网络函数:

$$[0109] \quad N(x) = f(x, w, b, l, n) \quad (3)$$

[0110] 其中, $N(x)$ 为神经网络的输出向量; x 为神经网络的输入向量,包括中子慢化方程、原函数变换方程、散射源原函数定解约束条件、能量初始条件和通量密度非负边界条件; w 为神经网络的连接权重; b 为神经网络的偏置项; l 为神经网络的深度; n 为神经网络的隐藏神经单元个数; f 为激活函数。

[0111] 中子慢化方程是一种简化的中子输运方程,参考求解中子输运方程的方法,其边界通常包括全反射边界、真空边界、零边界、非负边界等形式,通常按照常规方程处理即可。需要说明的是,由于均匀系统不存在几何、角度变量,因此,对应的中子慢化方程没有几何与角度方向的边界,但由于中子慢化方程是时滞方程,其求解域最高能量上的慢化能谱对方程的求解存在影响,因此,应设置最高能量点相应的初始条件,便于中子慢化方程的求解。

[0112] 本实施例中,作为其中一种可实现的方式,参考传统的超精细群计算方法,针对对数能降基准点到中子慢化方程最高能量起始边界点的能谱,设定为固定值 C_0 ,即可设置边界点 u_0 以上能量段慢化能谱相等,且该能量段 $\Sigma_t(u)$ 、 $\sigma_{s,k}(u)$ 截面数据也设定为 u_0 处的截面数据,即有:

$$[0113] \quad \phi(u) = C_0, \Sigma_t(u) = \Sigma_t(u_0), \sigma_{s,k}(u) = \sigma_{s,k}(u_0), 0 < u < u_0 \quad (9)$$

[0114] 将式(9)进行整理并代入组合函数,得到中子慢化方程求解的约束条件方程组为:

$$[0115] \quad \left\{ \begin{array}{l} M(u) = e^{-u} \sum_{k=1} \left[F_{k,0}(u) - F_{k,0}\left(u - \ln \frac{1}{\alpha_k}\right) \right] \\ F_{k,0}'(u) = \frac{N_k \sigma_{s,k}(u) M(u)}{(1 - \alpha_k) \Sigma_t(u)} e^u \\ u = 0, F_{k,0}(0) = 0 \\ M(u) / \Sigma_t(u_0) = C_0, 0 < u < u_0 \\ M(u) > 0, F_{k,0}(u) > 0 \end{array} \right. \quad (10)$$

[0116] 本实施例中,作为其中一种可实现的方式,中子慢化方程损失函数通过以下步骤获得:

[0117] 令 $N_M(x_u) = M(u)$, $N_{F_{k,0}}(x_u) = F_{k,0}(u)$,其中, x_u 为神经网络输入变量,表示中子慢化方程对数能降;

[0118] 将 $N_M(x_u) = M(u)$, $N_{F_{k,0}}(x_u) = F_{k,0}(u)$ 代入式(10)的第1项,得到残差形式表示的中子慢化方程损失函数:

$$[0119] \quad Loss_{M^f} = \frac{1}{|i|} \sum_i \left[N_M(x_u^i) - e^{-u} \sum_k \left[N_{F_{k,0}}(x_u^i) - N_{F_{k,0}} \left(x_u^i - \ln \frac{1}{\alpha_k} \right) \right] \right]^2 \quad (11)$$

[0120] 其中, i 为机器学习所需要的样本点, 可按照一定的概率密度分布方法生成。

[0121] 本实施例中, 作为其中一种可实现的方式, 原函数变换方程损失函数通过以下步骤获得:

[0122] 对于式 (10) 的第2项, 令 $N_{F_{k,0}}(x_u) = F_{k,0}(u)$, 得到原函数变换方程损失函数:

$$[0123] \quad Loss_{F_{k,0}^d} = \frac{1}{|i|} \sum_i \left[N_{F_{k,0}}(x_u^i)' - \frac{N_k \sigma_{s,k}(u^i) N_M(x_u^i)}{(1 - \alpha_k) \Sigma_t(u^i)} e^{u^i} \right]^2 \quad (12)$$

[0124] 其中, 式 (12) 机器学习样本的取值范围与式 (11) 相同。

[0125] 本实施例中, 作为其中一种可实现的方式, 散射源原函数定解约束损失函数通过以下步骤获得:

[0126] 对于式 (10) 的第3项, 令 $N_{F_{k,0}}(x_u) = F_{k,0}(u)$, 得到散射源原函数定解约束损失函数:

$$[0127] \quad Loss_{F_{k,0}^a} = \left[N_{F_{k,0}}(0) - F_{k,0}(0) \right]^2 = \left[N_{F_{k,0}}(0) \right]^2 \quad (13)$$

[0128] 中子慢化方程针对的是共振能群部分的能谱求解, 由于时滞方程的特点, 必须考虑求解域最高能量以上初始条件, 本实施例中, 作为其中一种可实现的方式, 参考式 (10) 的第4项, 其对应的损失函数为:

$$[0129] \quad Loss_{M^{b_u}} = \frac{1}{|j|} \sum_j \left[\frac{N_M(x_u^j)}{\Sigma_t(u_0)} - C_0 \right]^2, 0 < x_u^j < u_0 \quad (14)$$

[0130] 式中, j 为 $0 < u < u_0$ 之间的机器学习样本点;

[0131] 相应的对于原函数 $F_{k,0}(u)$, 根据式 (10) 的第2项, 其对应的损失函数为:

$$[0132] \quad Loss_{F_{k,0}^{b_u}} = \frac{1}{|j|} \sum_j \left[N_{F_{k,0}}'(x_u^j) - \frac{N_k \sigma_{s,k}(u_0) N_M(x_u^j)}{(1 - \alpha_k) \Sigma_t(u_0)} e^{u^j} \right]^2, 0 < x_u^j < u_0 \quad (15)$$

[0133] 本实施例中, 作为其中一种可实现的方式, 对于慢化能谱的通量密度及原函数为非负函数, 相应的边界条件对应式 (10) 最后一项, 其损失函数为:

$$Loss_{M^{b_{abs}}} = \frac{1}{|i|} \sum_i \left[N_M(x_u^i) - abs(N_M(x_u^i)) \right]^2 \quad (16)$$

[0134]

$$Loss_{F_{k,0}^{b_{abs}}} = \frac{1}{|i|} \sum_i \left[N_{F_{k,0}}(x_u^i) - abs(N_{F_{k,0}}(x_u^i)) \right]^2 \quad (17)$$

[0135] 式中, $abs()$ 为取绝对值函数。

[0136] 本实施例中, 作为其中一种可实现的方式, 针对组合函数 $M(u)$ 对应的神经网络 $N_M(x_u)$, 选择慢化方程及相应的边界条件损失函数进行加权, 得到加权后的单一损失函数:

$$[0137] \quad Loss_{M^{all}} = P_{M^f} Loss_{M^f} + P_{M^{b_u}} Loss_{M^{b_u}} + P_{M^{b_{abs}}} Loss_{M^{b_{abs}}} \quad (18)$$

[0138] 式中, P_{M^f} 、 $P_{M^{b_u}}$ 、 $P_{M^{b_{abs}}}$ 分别为中子慢化方程损失函数、能量初始条件损失函数、非

负边界条件损失函数对应的权重,一般根据试验与经验系数确定值。

[0139] 本实施例中,作为其中一种可实现的方式,对散射源原函数方程对应的不同神经网络函数 $N_{F_{k,0}}(x_u)$,分别选择相应的原函数变换方程、确定解约束、能量初始条件、非负边界条件构造加权损失函数,得到:

$$[0140] \quad Loss_{F_{k,0},all} = P_{F_{k,0}^d} Loss_{F_{k,0}^d} + P_{F_{k,0}^a} Loss_{F_{k,0}^a} + P_{F_{k,0}^{b_u}} Loss_{F_{k,0}^{b_u}} + P_{F_{k,0}^{b_{abs}}} Loss_{F_{k,0}^{b_{abs}}} \quad (19)$$

[0141] 式中, $P_{F_{k,0}^d}$ 、 $P_{F_{k,0}^a}$ 、 $P_{F_{k,0}^{b_u}}$ 、 $P_{F_{k,0}^{b_{abs}}}$ 分别为核素k对应的积分项原函数变换方程损失函数、确定解约束损失函数、能量初始条件损失函数、非负边界条件损失函数对应的权重。

[0142] 本实施例中,作为其中一种可实现的方式,式(19)中若用同一个神经网络的多个输出分别表示不同核素对应的 $F_{k,0}(u)$,则总体的损失函数表示为:

$$[0143] \quad Loss_{F_{0,all}} = \sum_{k=1}^K (P_{F_{k,0}^d} Loss_{F_{k,0}^d} + P_{F_{k,0}^a} Loss_{F_{k,0}^a} + P_{F_{k,0}^{b_u}} Loss_{F_{k,0}^{b_u}} + P_{F_{k,0}^{b_{abs}}} Loss_{F_{k,0}^{b_{abs}}}) \quad (20)$$

[0144] 对于 1H ,由于其 α 接近于0,从而导致式(4)关于 1H 的积分项的积分下限趋向于 $-\infty$,直接利用上述深度学习方法求解会导致训练结果不收敛。本实施例中,作为其中一种可实现的方式,步骤一中,将式(4)关于 1H 的积分项进行处理以便于深度学习训练;

[0145] 以求解域最高点能量上限的对数能降 u_0 为分界点将 1H 的积分项进行拆分,得到:

$$[0146] \quad \begin{aligned} \int_{u-\ln\frac{1}{\alpha_H}}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'-u} du' &= \int_{-\infty}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'-u} du' \\ &= e^{-u} \left(\int_{-\infty}^{u_0} \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \\ &= e^{-u} \left(\frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} \int_{-\infty}^{u_0} e^{u'} du' + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \quad (21) \\ &= e^{-u} \left(\frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} e^{u_0} + \int_{u_0}^u \frac{N_H \sigma_{s,H}(u') \phi(u')}{1-\alpha_H} e^{u'} du' \right) \end{aligned}$$

[0147] 在对数能量积分上限之下的积分项,由于通量变换较为平缓,故微观散射截面和通量可直接取求解域最高能量上限的值进行求解;

[0148] 由此,对第一项可进行简化,将积分号内的常数项取出,最终积分号下只剩下 $e^{u'}$ 这一项,可直接进行积分得到解析解;由式(21)可得中子慢化方程损失函数为:

$$[0149] \quad Loss_{\phi} = \frac{1}{|i|} \sum_i \left[N_{\phi}(\vec{x}_i) - e^{-\frac{\vec{r}}{x_i}} \left[\begin{aligned} &N_U(\vec{x}_i) - N_U \left(\vec{x}_i - \ln \frac{1}{\alpha_U} \right) + \\ &N_H(\vec{x}_i) - N_H(u_0) + A \end{aligned} \right] \right] \quad (22)$$

$$A = \frac{N_H \sigma_{s,H}(u_0) \phi(u_0)}{1-\alpha_H} e^{u_0} \quad (23)$$

[0150] 其余损失函数保持不变。

[0151] 由于全段训练会导致一次性需要训练的数据过多而造成训练精度不高以及当前

训练设备性能不支持训练庞大的数据集,本实施例中,在步骤五中,利用分段训练的方式来求解均匀多核素中子慢化方程,即通过将整个训练集化为一个个数据量合适的小训练集,并且以能量段为序依次由高向低进行训练,前一能群的训练集为后一能群的边界条件,以此求解均匀多核素中子慢化方程。

[0152] 本实施例中,作为其中一种可实现的方式,在步骤五中,深度学习求解过程中,第一群的求解方式同步骤三,从第二群开始,能量初始条件和原函数定解约束函数改为由前一群决定的边界条件损失函数。

[0153] 本实施例中,作为其中一种可实现的方式,在实际训练过程中,假设第 m 群的对数能降范围为 $u_{m-1}:u_m$, B_{m-1} 为 $u_{m-2}:u_{m-1}$ 范围内的某一常数。用 $N_{\phi,m}$ 和 $N_{k,0,m}$ 代表第 m 群的神经网络函数,则边界条件损失函数为:

$$Loss_{b,\phi} = \frac{1}{|j|} \sum_j [N_{\phi,m}(\vec{x}_j) - N_{\phi,m-1}(\vec{x}_j)]^2, B_{m-1} < \vec{x}_j < u_{m-1} \quad (24)$$

[0154]

$$Loss_{b,F,k} = \frac{1}{|j|} \sum_j [N_{k,0,m}(\vec{x}_j) - N_{k,0,m-1}(\vec{x}_j)]^2, B_{m-1} < \vec{x}_j < u_{m-1} \quad (25)$$

[0155] 式中, j 为机器学习所需要的样本点,可按照一定的概率密度分布生成,或者根据方程的形式采用不同密度分布策略生成。

[0156] 本实施例中,作为其中一种可实现的方式,将边界条件损失函数(24)和(25)替代能量初始条件和原函数定解约束函数进行加权,得到针对 $N_{\phi}(\vec{x})$ 深度学习损失函数

$Loss_{\phi-all}$,以及针对 $N_{k,0}(\vec{x})$ 的损失函数:

$$[0157] \quad Loss_{\phi-all} = P_{\phi} Loss_{\phi} + P_{b,\phi} Loss_{b,\phi} + P_{\phi-abs} Loss_{\phi-abs} \quad (26)$$

$$[0158] \quad Loss_{p-all-k} = P_p Loss_p + P_{b,F,k} Loss_{b,F,k} + P_{p-abs-k} Loss_{p-abs-k} \quad (27)$$

[0159] 式中, P_{ϕ} , $P_{b,\phi}$, $P_{\phi-abs}$, P_p , $P_{b,F,k}$, $P_{p-abs-k}$ 分别为对应损失函数的权重,为根据实验经验确定的可调节超参数,其中, $Loss_{p-all-k}$ 是假设存在多个原函数的情况,也就是核素数量大于等于2的情况。

[0160] 本实施例中,作为其中一种可实现的方式,将加权损失函数代入到神经网络进行交替迭代训练,即可分段求解中子慢化方程。

[0161] $F_{k,0}$ 和 F_k 分别表示不同的原函数, $F_{k,0}$ 表示原函数的一个定解,而 F_k 表示原函数的不确定解。 u 、 u' 在式中均为对数能降, u' 表示积分项内的被积对数能降的积分符号,而 u 是积分项外的对数能降的符号。

[0162] 本实施例中,作为其中一种可实现的方式,采用基于二氧化铀燃料构造的两种核素 ^{238}U 和 ^{16}O 的均匀系统开展对比验证实验。由于在典型反应堆系统中,共振效应由 ^{238}U 主导,首先测试深度学习方法对于单共振核素引起的能谱变化的预测能力,排除共振干涉等问题的干扰。共振计算的基准来自于利用公开文献“基于特征线法计算的超细群慢化方程求解方法”(秦帅,张乾,赵强,等.基于特征线法计算的超细群慢化方程求解方法[J].原子能科学技术,2019,53(12):8.D0I:10.7538/yzk.2018.youxian.0823.)中的UFG-MOC方法对本算例参数的计算结果,使用的截面为NJ0Y程序产生的基于ENDF/B-VII.0的超精细群点截面库,超精细群能群勒宽为0.000025,共振能群的多群结构与编号来自于WIMS格式69群数据库,

15~27群共包含309200个精细能群。为了简化起见,选择15~23群作为观察对象,这些能群包含了较为复杂的典型能谱振荡,适合用于检验深度学习方法的能谱预测能力。

[0163] 机器学习方法与参数选择如下:神经网络选用基本的全连接网络,设置隐藏单元 $n=40$,网络层数 $l=9$,激活函数选用 $\tanh$,网络初始值为高斯随机分布,采用ADAM机器学习算法;机器学习率从 10^{-4} 开始,随着学习次数增加逐渐下降,训练到损失函数不再下降为止。

[0164] 均匀系统总截面在能群上的偏差分布如图3所示,从右到左依次为15~23群。可以看出, ^{238}U 和 ^{16}O 构造的均匀系统总截面15~20群相对偏差小于0.4%,取得了较高的截面计算精度,随着能群数的增大相对偏差有所增加。图4给出深度学习方法与超精细群方法在共振能群第15~23群的能谱对比,能谱形状总体吻合较好。图5给出反应率组合函数随对数能量变化的趋势。图6给出 ^{238}U 在原函数 $F_{k,0}(u)$ 深度学习的计算结果,与传统超精细群方法的计算结果趋势十分吻合。以上数值算例说明深度学习方法具有准确捕捉慢化方程中物理特征的能力,从机理上保证了共振计算的精度。

[0165] 本实施例中,作为其中一种可实现的方式,采用两种核素 ^{238}U 和 ^1H 的均匀系统开展对比验证实验,机器学习方法与参数选择同上述 ^{238}U 和 ^{16}O 的均匀系统。图7展现了 ^{238}U 和 ^1H 构造的均匀系统总截面的计算结果。可以看出,深度学习方法对 ^{238}U 微观散射截面,以传统超精细群方法为基准, ^{238}U 分群截面计算误差小于0.3%,计算结果具有较高的精度,图8给出了深度学习方法与超精细群方法在共振能群第15至18四个能群内的能谱对比,能谱形状总体吻合较好。 ^{238}U 和 ^1H 对应的积分原函数 $F_{k,0}(u)$ 计算结果的如图9所示,与传统计算方法也符合良好。

[0166] 本实施例中,作为其中一种可实现的方式,采用3种核素 ^{235}U 、 ^{238}U 和 ^{16}O 的均匀系统,测试深度学习方法对实际二氧化铀燃料的能谱恢复能力。基准解来源不变,机器学习方法与参数选择与机器学习方法与参数选择同上述 ^{238}U 和 ^{16}O 的均匀系统一致。在这个问题中,引入了 ^{235}U 、 ^{238}U 的干涉效应,重点观察 ^{235}U 、 ^{238}U 微观截面的精度。慢化方程求解过程中仅需要材料的宏观总截面和各核素的微观散射截面。图10给出 ^{235}U 和 ^{238}U 的微观共振散射截面及 ^{235}U 、 ^{238}U 和 ^{16}O 构造均匀系统的总截面的对比及偏差分布,可以看出:深度学习方法对 ^{235}U 、 ^{238}U 微观散射截面,以传统超精细群方法为基准,15~20群 ^{235}U 分群散射截面计算相对偏差小于0.3%, ^{238}U 的小于0.7%,计算结果具有较高的精度;随着能群数的增大, ^{238}U 分群散射截面、总截面相对偏差有所增加。 ^{235}U 、 ^{238}U 和 ^{16}O 对应的积分原函数 $F_{k,0}(u)$ 计算结果如图11所示,可见与传统计算方法符合良好。上述计算结果表明深度学习方法具有良好的共振干涉效应问题处理能力。

[0167] 本实施例中,作为其中一种可实现的方式,构造四核素均匀系统 $^{238}\text{U}+^{16}\text{O}+^{90}\text{Zr}+^{239}\text{Pu}$,该问题考虑引入MOX燃料中的典型共振核素 ^{239}Pu 以及压水堆燃料栅元中的包壳材料 ^{90}Zr 。其中 ^{90}Zr 也作为共振核素处理,考虑包壳材料的共振效应。该问题具有更为复杂的多核素共振干涉效应,重点观察 ^{90}Zr 、 ^{239}Pu 和 ^{238}U 的微观截面计算结果。图12分别给出 ^{239}Pu 、 ^{90}Zr 和 ^{238}U 微观共振散射截面的对比及相对偏差分布,可见 ^{239}Pu 的截面相对偏差均小于0.1%, ^{90}Zr 的截面相对偏差均小于0.5%, ^{238}U 的截面相对偏差均小于0.7%。 ^{239}Pu 、 ^{90}Zr 和 ^{238}U 对应的积分原函数 $F_{k,0}(u)$ 计算结果如图13所示,可见与传统计算方法符合良好。

[0168] 传统超精细群方法参考公开文献“反应堆物理中的共振自屏计算”(张乾,吴宏春,曹良志.反应堆物理中的共振自屏计算[M].北京:国防工业出版社,2020.)。

[0169] 上述计算结果表明深度学习方法具有良好的共振干涉效应问题处理能力,且对复杂核素问题的截面计算仍保持了较高的计算精度。

[0170] 本实施例通过多个均匀系统算例进行数值计算,验证了提出方法原理及计算流程的正确性,并具有解决多核素共振干涉问题的能力。验证计算结果得到了慢化能谱随能量的连续分布,证明了所提出的方法在慢化能谱局部特性分辨能力上具有潜在优势,探索了求解中子慢化方程的新方式。

[0171] 以上所述实施例仅表达了本发明的几种实施方式,其描述较为具体和详细,但不能因此而理解为对本发明专利范围的限制。应当指出的是,对于本领域的普通技术人员来说,在不脱离本发明构思的前提下,还可以做出若干变形和改进,都属于本发明保护的范围。因此,本发明专利的保护范围应以所附权利要求为准。




图1




图2




图3




图4




图5




图6




图7




图8




图9




图10(a)




图10(b)




图10(c)




图11




图12(a)




图12(b)




图12(c)




图13